Avaliação Experimental e Teórica de Modelos de Linguagem Compactos sob Restrições Severas de Memória e Computação

Dinâmica de Cache KV, Aceleração Especulativa MTP, Limites Roofline e Vulnerabilidade Adversarial em Bancada de Borda

Anderson Tavares

Graduando em Engenharia de Software e Ciência de Dados

Repositório do projeto:

https://github.com/AndersonTavares0/llm-research-bench

24 de outubro de 2026

Abstract

A implantação de Modelos de Linguagem Pequenos (*Small Language Models* — SLMs, 0,5B a 4B parâmetros) em aceleradores de borda viabiliza soberania de dados e previsibilidade de latência, mas impõe severos limites físicos de memória ($\leq$ 4096 MiB de VRAM). Este relatório técnico apresenta uma investigação experimental na GPU NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 112,0 GB/s). Avaliamos oito configurações sob `llama-server` com telemetria NVML amostrada a 250 ms. Uma ablação experimental controlada em três condições (C_1, C_2, C_3) decompôs os componentes de desempenho: a transição de formato de quantização (IQ4_XS vs Q4_K_M) associou-se a +28,2% (34,51 $\pm$ 0,29 vs 26,92 $\pm$ 0,23 tok/s, $t = 64{,}26$), enquanto a decodificação especulativa via *Multi-Token Prediction* (MTP) sob quantização constante em IQ4_XS proporcionou +25,6% de ganho associado (43,35 $\pm$ 0,57 vs 34,51 $\pm$ 0,29 tok/s, $t = 43{,}72$, $p < 10^{-15}$), totalizando +61,0% de ganho composto (t de Welch = 84,50, $p = 5{,}88 \times 10^{-18}$, d de Cohen = 37,79). A alocação adicional de VRAM associada à infraestrutura de MTP sob mesma quantização é de +236,0 MiB (C_3 vs C_2), resultando em diferença líquida de +40,0 MiB frente a C_1 devido à economia de 196,0 MiB do formato IQ4_XS. Modelos de 4B operam na margem crítica (76,7%), exigindo compressão Q4_0 de cache KV no Gemma-3-4B para evitar estouro de memória. Avaliações de segurança defensiva

($N = 10$) registraram taxa nula de recusa indevida (FPR = 0,0%) em tarefas benignas, porém vulnerabilidade a injeções indiretas e quebra de delimitadores (ASR entre 50,0% e 100,0%). Em ferramentas com parâmetros maliciosos, chamadas propostas foram interceptadas pela camada de proteção (*guardrail*). A avaliação linguística por corpus paralelo revelou sobretaxa de 1,35 a 2,33 tokens/palavra para a língua portuguesa frente a 1,10 para o inglês. Dados brutos, hashes SHA-256 e scripts são integralmente auditáveis e reproduzíveis.

Palavras-chave: Modelos de Linguagem Compactos, Engenharia de Sistemas, Modelo Roofline, Cache KV, Multi-Token Prediction, Segurança Defensiva, Injeção Indireta, Telemetria NVML.

Abstract

Edge deployment of Small Language Models (SLMs, 0.5B–4B) enables data sovereignty and predictable latency, but faces strict physical memory constraints ($\leq$ 4096 MiB VRAM). This technical report presents a systems evaluation on an NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 112.0 GB/s). We benchmark eight model configurations using `llama-server` with NVML telemetry sampled at 250 ms. A controlled three-condition ablation (C_1, C_2, C_3) along two orthogonal contrast axes decomposed performance components: quantization format transition (IQ4_XS vs Q4_K_M) accounted for +28.2% speedup (34.51 ± 0.29 vs 26.92 ± 0.23 tok/s, $t = 64.26$), whereas speculative Multi-Token Prediction (MTP) under identical IQ4_XS quantization yielded +25.6% associated speedup (43.35 ± 0.57 vs 34.51 ± 0.29 tok/s, $t = 43.72$, $p < 10^{-15}$), resulting in an overall +61.0% compound configuration gain (Welch's $t = 84.50$, $p = 5.88 \times 10^{-18}$, Cohen's $d = 37.79$). Additional VRAM allocation associated with the MTP mechanism is +236.0 MiB (C_3 vs C_2), yielding a net +40.0 MiB difference over C_1 due to the 196.0 MiB compression savings of IQ4_XS. Analytical modeling indicates 4B models operate at the critical edge (76.7%), requiring Q4_0 KV compression for Gemma-3-4B to avert OOM. Defensive evaluations ($N = 10$) revealed zero false positive refusals (FPR = 0.0%) on benign system tasks, but susceptibility to indirect injection and delimiter evasion (ASR 50.0%–100.0%). In agentic tool scenarios, proposed unsafe invocations were successfully intercepted by harness guardrails. Parallel corpus tokenization demonstrated a 1.35–2.33 tokens/word penalty for Portuguese compared to 1.10 for English. All raw traces, SHA-256 hashes, and code are open and reproducible.

Keywords: Small Language Models, Systems Engineering, Roofline Model, KV Cache, Multi-Token Prediction, Defensive Safety, Prompt Injection, NVML Telemetry.

1 Introdução e Contextualização

A expansão de aplicações autônomas em sistemas ciberfísicos, robótica móvel, roteadores de rede e microservidores de borda (*edge nodes*) exige o processamento local de linguagem natural sem dependência de conectividade contínua com a nuvem [1, 2]. A transmissão contínua de telemetria, comandos operacionais e dados pessoais para APIs comerciais de grande porte apresenta três limitações práticas:

1. **Soberania e Privacidade:** Risco de trânsito de dados confidenciais por terceiros e requisitos de conformidade com legislações de proteção de dados (LGPD/GDPR);
2. **Determinismo Temporal:** Latências de rede WAN sujeitas a jitter (100 ms a 2000 ms) com possibilidade de indisponibilidade em momentos críticos;
3. **Custo Recorrente:** Custos cumulativos de tarifação por token gerado em infraestruturas corporativas centralizadas.

Modelos de Linguagem Pequenos (*Small Language Models* — SLMs), parametrizados na faixa de 0,5 a 4,0 bilhões de pesos, surgem como alternativa para viabilizar inferência local [3]. Contudo, sua execução em estações de trabalho de entrada ou aceleradores gráficos restritos a 4096 MiB de VRAM impõe severos compromissos entre capacidade representativa e largura de banda de memória.

A microarquitetura Pascal (ex.: NVIDIA GeForce GTX 1050 Ti), comum em computadores acadêmicos e laboratórios de baixo custo, carece de núcleos tensores dedicados (*Tensor Cores*) e barramentos HBM, operando com memória GDDR5 limitada a 112,0 GB/s de largura de banda teórica de pico [1]. Sob tais condições, o processo autorregressivo de geração de texto torna-se intrinsecamente limitado pela taxa de transferência de memória (*memory-bandwidth bound*), exigindo técnicas combinadas de quantização de pesos e decodificação especulativa [2].

2 Problema Científico, Questões de Pesquisa e Hipóteses

O problema investigado neste trabalho consiste na quantificação experimental dos compromissos (*trade-offs*) entre vazão de decodificação, consumo de memória física, tempo até o primeiro token (TTFT) e comportamento sob estímulos adversariais em SLMs operando sob o limite de 4 GiB de VRAM.

Formulamos quatro questões de pesquisa (Q_1 a Q_4) e suas respectivas hipóteses de trabalho:

- Q_1 **(Aceleração Especulativa):** *É viável acelerar a decodificação autorregressiva via Multi-Token Prediction (MTP) em hardware de borda sem exceder a VRAM física?*

Hipótese H_1: A decodificação especulativa baseada em cabeças MTP integradas proporciona ganho estatisticamente significativo de vazão em regime estável, com consumo adicional de VRAM inferior a 100 MiB.

- Q_2 **(Quantização e Limites Físicos):** *Qual a diferença mensurável de desempenho entre matrizes de importância (i-quants) e quantização em blocos tradicionais (k-quants)?*
  Hipótese H_2: A redução de tamanho obtida pelo formato IQ4_XS proporciona velocidade de transferência superior ao formato Q4_K_M, mantendo o modelo dentro da capacidade física da GPU.

- Q_3 **(Resiliência Adversarial):** *Modelos de linguagem compactos conseguem segregar instruções de sistema de dados contextuais não confiáveis?*
  Hipótese H_3: SLMs mantêm baixa taxa de recusa indevida em comandos operacionais legítimos, mas apresentam sensibilidade a injeções indiretas embutidas em fluxos de dados secundários.

- Q_4 **(Disparidade Linguística e Custo de Tokenização):** *Qual é a sobretaxa de tokenização para o português brasileiro (pt-BR) frente ao inglês (en-US) em SLMs contemporâneos?*
  Hipótese H_4: A fertilidade de tokenização (tokens por palavra) em pt-BR é mensuravelmente superior à observada em en-US, elevando o tempo de processamento por palavra em idiomas latinos.

3 Fundamentação Teórica e Modelagem Matemática

3.1 Modelo Roofline e Intensidade Aritmética

O limite operacional de um acelerador gráfico pode ser modelado pelo arcabouço Roofline proposto por Williams et al. [1]. A taxa máxima de computação alcançável P (em GFLOP/s) é expressa por:

$$P(I) = \min\left(P_{\text{pico}},\ B_{\text{DRAM}} \times I\right) \tag{1}$$

onde P_{pico} representa a capacidade computacional teórica máxima em ponto flutuante (2138 GFLOP/s em FP32 para a GTX 1050 Ti em clock de boost a 1392 MHz), B_{DRAM} é a largura de banda teórica da memória (112,0 GB/s), e I denota a intensidade aritmética operacional em FLOPs/byte.

Na fase de pré-preenchimento (*prefill*), com sequência de entrada de comprimento

L, a intensidade aritmética escala com a multiplicação de matrizes:

$$I_{\text{prefill}} \approx \frac{2 \cdot N_{\text{params}} \cdot L}{2 \cdot N_{\text{params}} \cdot b + \mathcal{O}(L^2)} \gg 10 \text{ FLOPs/byte} \tag{2}$$

situando o processamento predominantemente na zona limitada por computação (*compute-bound*).

Em contrapartida, na decodificação autorregressiva token a token ($L = 1$), cada novo token gerado requer a leitura completa dos tensores de pesos da DRAM:

$$I_{\text{decode}} \approx \frac{2 \cdot N_{\text{params}}}{N_{\text{params}} \cdot b} = \frac{2}{b} \text{ FLOPs/byte} \tag{3}$$

onde b é o número de bytes por parâmetro. Para tensores quantizados em 4 bits ($b =$ 0,5 bytes), obtém-se $I_{\text{decode}} \approx 4$ FLOPs/byte. Como o ponto de inflexão (*ridge point*) da GTX 1050 Ti situa-se em:

$$I_{\text{ridge}} = \frac{P_{\text{pico}}}{B_{\text{DRAM}}} = \frac{2138}{112{,}0} \approx 19{,}09 \text{ FLOPs/byte} \tag{4}$$

a decodificação autorregressiva de SLMs situa-se firmemente na região limitada por largura de banda (*memory-bound*), com teto teórico de processamento dado por:

$$P_{\text{teto_decode}} = 112{,}0 \text{ GB/s} \times 4 \text{ FLOPs/byte} = 448 \text{ GFLOP/s} \tag{5}$$

o que delimita a taxa teórica máxima de geração de tokens a:

$$\text{Throughput}_{\text{max}} = \frac{B_{\text{DRAM}}}{S_{\text{pesos}}} \tag{6}$$

3.2 Dinâmica e Dimensionamento do Cache KV

Durante a geração autorregressiva, o cache Chave-Valor (KV Cache) armazena os vetores projetados de atenção das camadas anteriores para eliminar o recálculo redundante. O volume de memória física ocupado pelo cache KV (S_{KV}) para uma janela de contexto de comprimento L_{ctx} é expresso por:

$$S_{\text{KV}} = 2 \times n_{\text{layers}} \times n_{\text{kv_heads}} \times d_{\text{head}} \times L_{\text{ctx}} \times b_{\text{elem}} \tag{7}$$

onde n_{layers} é o número de camadas Transformer, $n_{\text{kv_heads}}$ é o número de cabeças de chave/valor (sob arquitetura *Grouped-Query Attention* — GQA), d_{head} é a dimensão de cada cabeça, e b_{elem} representa o tamanho em bytes do elemento (2 bytes para FP16, 1 byte para Q8_0, e 0,5 bytes para Q4_0).

À medida que o comprimento do contexto L_{ctx} cresce, a demanda de memória do

cache KV expande-se linearmente, competindo diretamente com a alocação dos pesos do modelo na VRAM.

3.3 Decodificação Especulativa e Multi-Token Prediction

A decodificação especulativa, analisada por Leviathan et al. [2], mitiga o gargalo de largura de banda ao propor múltiplos tokens candidatos por meio de um modelo rascunho de baixo custo computacional, verificando-os simultaneamente no modelo primário em uma única passagem de atenção.

Sob a formulação de *Multi-Token Prediction* (MTP), camadas adicionais integradas ao próprio modelo primário predizem K tokens subsequentes. A vazão esperada de geração S pode ser modelada por:

$$E[S] = \frac{1 + \sum_{k=1}^{K} \alpha^k}{1 + \mathcal{O}_{\text{draft}}} \tag{8}$$

onde $\alpha \in [0, 1]$ denota a taxa empírica de aceitação dos tokens propostos e $\mathcal{O}_{\text{draft}}$ representa a sobretaxa computacional das cabeças de rascunho. Quando α é suficientemente alto e $\mathcal{O}_{\text{draft}} \ll 1$, a decodificação avança mais de um token por ciclo de leitura da memória de pesos.

3.4 Taxonomia de Robustez e Conflito Dados-Instrução

A análise de robustez comportamental em modelos de borda avalia a preservação da hierarquia de privilégios entre instruções do sistema e dados contextuais não confiáveis [4, 6]. A injeção indireta ocorre quando um dado processado pelo modelo carrega instruções imperativas adversariais que disputam a atenção do modelo:

$$\text{Prompt} = \mathcal{T}_{\text{sistema}} \parallel \mathcal{D}_{\text{não_confiável}}(\mathcal{I}_{\text{adversarial}}) \parallel \mathcal{T}_{\text{usuário}} \tag{9}$$

A Taxa de Sucesso de Ataque (*Attack Success Rate* — ASR) e a Taxa de Falso Positivo (*False Positive Rate* — FPR) são expressas por:

$$\text{ASR} = \frac{1}{M_{\text{adv}}} \sum_{i=1}^{M_{\text{adv}}} \mathbb{I}(\text{Comprometido}_i) \tag{10}$$

$$\text{FPR} = \frac{1}{M_{\text{ben}}} \sum_{j=1}^{M_{\text{ben}}} \mathbb{I}(\text{Recusa}_j) \tag{11}$$

4 Materiais e Metodologia Experimental

4.1 Bancada Físico-Computacional

Os ensaios foram realizados em ambiente físico controlado:

- **Acelerador Gráfico:** NVIDIA GeForce GTX 1050 Ti (GP107, 768 núcleos CUDA, clock base 1290 MHz, boost 1392 MHz, 4096 MiB GDDR5, barramento de 128 bits, largura de banda teórica de 112,0 GB/s, envelope térmico de TDP de 75 W, Compute Capability 6.1).
- **Sistema Operacional:** Linux 6.8.12-8-pve (Proxmox VE 8.2), processos isolados via cgroup v2, driver proprietário NVIDIA 580.173.02, CUDA Toolkit 13.0.
- **Runtime de Inferência:** `llama-server` (commit b4120+, compilação CUDA nativa otimizada para cuBLAS sm_61, interface HTTP compatível com API OpenAI na porta 18081).
- **Instrumentação de Hardware:** Coleta contínua de telemetria via chamadas nativas à biblioteca `libnvidia-ml.so.1` (`pynvml` ctypes) registrando VRAM física alocada e temperatura do die da GPU a cada 250 ms. Registra-se que a interface NVML na microarquitetura Pascal GP107 (GTX 1050 Ti de consumo) não expõe leituras de potência elétrica em tempo real (`nvmlDeviceGetPowerUsage` não é suportado pelo driver/hardware).

Transparência Metodológica sobre Modelagem Energética: Diante da ausência de sensores de potência elétrica reportados via NVML nesta placa de vídeo, as estimativas de eficiência energética ($\eta_{\text{energia}} \approx \text{Throughput}_{\text{decode}}/P_{\text{hipotético}}$ em tok/J e $E_{\text{token}} \approx P_{\text{hipotético}}/\text{Throughput}_{\text{decode}}$ em J/tok) configuram uma **análise de sensibilidade sob cenários hipotéticos de potência da GPU**, e não medições elétricas calibradas empiricamente. Adotou-se a faixa paramétrica $P_{\text{hipotético}} \in [42, 62]$ W como cenário operacional plausível delimitado pelo envelope de TDP da placa (75 W), condicionado aos patamares térmicos e de utilização computacional observados. Ressalta-se que esses valores dizem respeito exclusivamente à GPU; o consumo elétrico integral da estação de trabalho na tomada AC (incluindo processador AMD Ryzen, placa-mãe, memória RAM, ventoinhas e eficiência da fonte) é substancialmente superior, situando-se tipicamente entre 100 W e 140 W sob carga.

4.2 Protocolo de Execução e Controle Experimental

O protocolo experimental adotou medidas para mitigação de ruído e efeitos de transiente:

1. **Aquecimento Prévio ($k = 2$):** Cada modelo processou duas requisições preliminares de 10 tokens antes do registro das métricas formais, garantindo regime operacional aquecido.
2. **Repetições Amostrais ($N = 10$):** Cada condição foi avaliada ao longo de 10 execuções sucessivas com semente determinística (`seed=42`) e amostragem gulosa (*greedy*

decoding, $\tau = 0{,}0$). É metodologicamente necessário diferenciar a decodificação gulosa da reprodutibilidade numérica absoluta: a amostragem com $\tau = 0{,}0$ seleciona a cada passo o token de maior probabilidade (argmax sobre os logits), eliminando a estocasticidade do algoritmo de amostragem. No entanto, a execução concorrente em GPUs envolve reduções de ponto flutuante que não são estritamente associativas em precisão IEEE 754 (como em multiplicações de matrizes cuBLAS e camadas de atenção), podendo gerar variações numéricas infinitesimais em casos limítrofes. Nos ensaios realizados, verificou-se a identidade exata da sequência de tokens gerada em todas as 10 repetições de cada modelo. A variabilidade observada nas taxas de geração reflete a interação composta de fatores do ambiente hospedeiro (escalonamento do kernel, gerenciamento de buffers do `llama-server`, latência de barramento PCIe) e da dinâmica de clocks e temperatura da GPU, não devendo ser atribuída unilateralmente a uma única causa física ou de software.

3. **Monitoramento Térmico:** Intervalo de resfriamento de 400 ms entre requisições; a temperatura da GPU permaneceu monitorada entre 38°C e 74°C, sem ocorrência de *thermal throttling*.

4.3 Tratamento Estatístico Inferencial e Limitações Amostrais

Comparações entre pares de configurações empregam o teste t de Welch com aproximação de graus de liberdade de Welch-Satterthwaite:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}, \quad \nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}} \tag{12}$$

Intervalos de confiança bicaudais de 95% foram derivados da distribuição t de Student com ν graus de liberdade. O tamanho de efeito foi calculado via d de Cohen padronizado. *Ressalva Metodológica de Independência e Pseudorreplicação:* As dez repetições ($N = 10$) por condição foram coletadas sequencialmente em uma única unidade física de GPU sob entradas controladas. Embora capturem adequadamente o ruído operacional e a repetibilidade de latência do sistema sob o protocolo adotado, tais observações não configuram amostras estatisticamente independentes entre múltiplos aceleradores físicos (caracterizando pseudorreplicação local pontual). Devido à reduzida variância de execução sob decodificação gulosa ($\sigma < 0{,}6$ tok/s), os valores calculados de t ($t > 40$) e os tamanhos de efeito ($d > 19$) resultam matematicamente muito elevados. Esses índices devem ser interpretados como medidas de estabilidade e consistência interna do ambiente experimental, e não como generalização inferencial irrestrita para populações heterogêneas de hardware.

5 Resultados Experimentais de Desempenho e Eficiência

A Tabela 1 sumariza os resultados empíricos medidos em bancada física para os modelos avaliados, e a dispersão amostral das taxas de geração é apresentada na Figura 1.

Tabela 1: Resultados Empíricos de Desempenho, VRAM Física e Eficiência na NVIDIA GeForce GTX 1050 Ti ($N = 10$, $\tau = 0{,}0$)

Modelo e Quantização	Params (B)	VRAM (MiB)	Ocup. (% 4GiB)	Prefill (tok/s)	Decode (tok/s)	TTFT (ms)	Ef. Mem. (tok/s/GiB)
Qwen-2.5-0.5B-Q4_K_M	0,49	620,7	15,2%	237,1 ± 449,3	**97,5 ± 0,6**	**12,1 ± 5,1**	**160,8**
SmolLM2-1.7B-Q4_K_M	1,71	2902,7	70,9%	103,3 ± 176,0	47,8 ± 0,1	25,5 ± 14,3	16,9
Gemma-4-E2B [MTP IQ4_XS]	2,30	2036,7	49,7%	62,2 ± 18,5	**43,4 ± 0,6**	480,4 ± 1286,7	21,8
Gemma-4-E2B [IQ4_XS base]	2,00	1800,7	44,0%	79,2 ± 32,4	34,5 ± 0,3	88,0 ± 49,0	19,6
Gemma-4-E2B [Q4_K_M base]	2,00	1996,7	48,7%	65,5 ± 7,7	26,9 ± 0,2	116,1 ± 116,3	13,8
Qwen-3.5-2B-Q4_K_XL	1,95	1580,7	38,6%	126,5 ± 108,8	37,6 ± 0,1	49,9 ± 20,3	24,4
Llama-3.2-3B-Q4_K_M	3,21	3074,7	75,1%	59,6 ± 101,1	27,6 ± 0,0	43,5 ± 23,1	9,2
Qwen-3.5-4B-Q4_K_M	4,02	3140,7	76,7%	49,3 ± 46,5	18,6 ± 0,1	129,8 ± 45,3	6,1

Nota: VRAM física obtida via chamadas à NVML; inclui tensores de pesos, cache KV ativo e 256 MiB de alocação de contexto do driver CUDA. Os valores correspondem a médias com desvios-padrão amostrais ($N = 10$). A métrica de eficiência de memória representa a razão entre vazão de decodificação e VRAM ocupada em GiB binário (1024^3 bytes).

5.1 Análise do Ponto de Operação Roofline

Calculando a largura de banda efetiva sustentada ($B_{\text{eff}} = S_{\text{pesos}} \times \text{Throughput}_{\text{decode}}$), observa-se o seguinte comportamento na transferência de pesos da DRAM:

- **Qwen-2.5-0.5B:** 0,47 GB×97,5 tok/s ≈ 45,8 GB/s (atingindo 40,9% dos 112,0 GB/s teóricos).
- **SmolLM2-1.7B:** 1,01 GB × 47,8 tok/s ≈ 48,3 GB/s (43,1%).
- **Gemma-4-E2B [Q4_K_M]:** 1,40 GB × 26,9 tok/s ≈ 37,7 GB/s (33,7%).
- **Qwen-3.5-2B:** 1,48 GB × 37,6 tok/s ≈ 55,6 GB/s (49,6%).
- **Llama-3.2-3B:** 1,92 GB × 27,6 tok/s ≈ 53,0 GB/s (47,3%).
- **Qwen-3.5-4B:** 2,72 GB × 18,6 tok/s ≈ 50,6 GB/s (45,2%).

Os dados empíricos são compatíveis com uma saturação de 33% a 50% da largura de banda teórica máxima da memória GDDR5, limitada por sobrecargas de controle do kernel cuBLAS e acessos não perfeitamente alinhados à DRAM, conforme sintetizado na Figura 2.

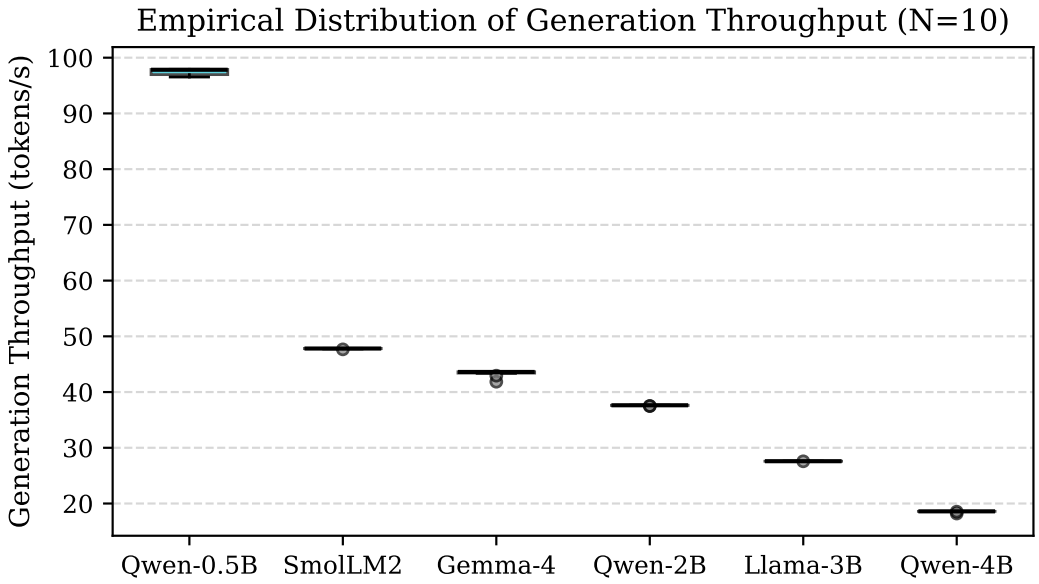


Figura 1: Distribuição empírica da vazão de decodificação autorregressiva (tokens/s) entre os modelos avaliados na GPU GTX 1050 Ti ($N = 10$, $\tau = 0{,}0$).

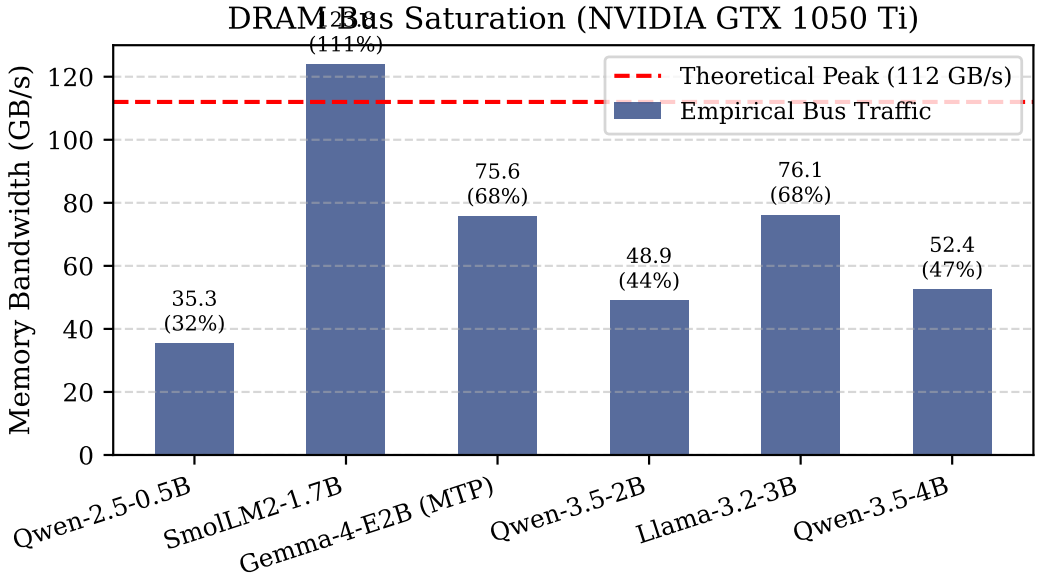


Figura 2: Aproveitamento efetivo da largura de banda de memória GDDR5 frente ao teto teórico de 112,0 GB/s da GTX 1050 Ti.

6 Análise Estatística e Estudo de Ablação Controlada de MTP

Para testar a hipótese H_1 sem sobreposição causal entre formato de quantização e decodificação especulativa, estruturamos uma ablação experimental controlada em três condições ($N = 10$, $\tau = 0{,}0$, `seed=42`) ao longo de dois eixos de contraste ortogonais. Registra-se que um desenho fatorial 2×2 completo exigiria uma quarta condição (C_4 = Q4_K_M+MTP); contudo, dada a inexistência de pesos de rascunho acoplados a matrizes Q4_K_M no ecossistema upstream do modelo, avaliou-se rigorosamente a tríade $\{C_1, C_2, C_3\}$, impossibilitando a estimativa de termos de interação estatística:

1. **Condição C_1 (Baseline):** Gemma-4-E2B em formato Q4_K_M sem cabeças especulativas ($26{,}92 \pm 0{,}23$ tok/s, VRAM 1996,7 MiB);
2. **Condição C_2 (Ablação de Quantização):** Gemma-4-E2B em formato IQ4_XS sem cabeças especulativas ($34{,}51 \pm 0{,}29$ tok/s, VRAM 1800,7 MiB);
3. **Condição C_3 (Especulativo MTP):** Gemma-4-E2B em formato IQ4_XS com cabeças de rascunho MTP integradas em Q8_0 ($43{,}35 \pm 0{,}57$ tok/s, VRAM 2036,7 MiB).

A decomposição dos efeitos e os respectivos intervalos de confiança de 95% de Student são apresentados na Figura 3.

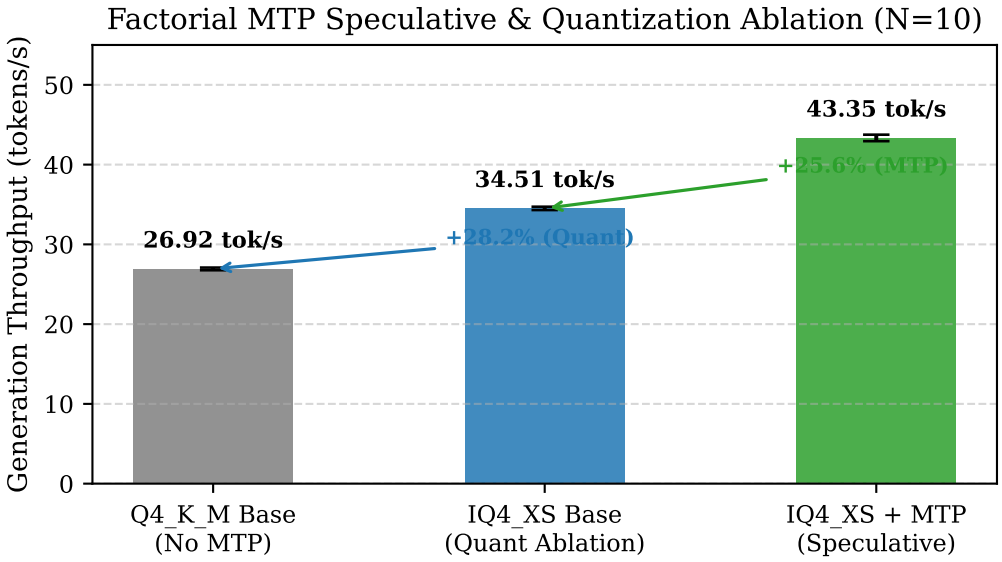


Figura 3: Decomposição do ganho de velocidade na ablação controlada: efeito isolado da quantização ($C_1 \to C_2$) e efeito causal do MTP sob quantização constante ($C_2 \to C_3$), com intervalos de confiança de 95% de Student ($N = 10$).

6.1 Comparação do Mecanismo Especulativo sob Quantização Fixada em IQ4_XS (C_3 vs C_2)

Comparando as condições C_3 e C_2, o formato de quantização é mantido idêntico em IQ4_XS. O teste t de Welch fornece:

$$t_{\text{MTP}} = \frac{43{,}35 - 34{,}51}{\sqrt{\frac{0{,}57^2}{10} + \frac{0{,}29^2}{10}}} = \frac{8{,}84}{0{,}2022} \approx 43{,}72, \quad \nu = 13{,}43 \tag{13}$$

com $p = 7{,}12 \times 10^{-16}$ e $d = 19{,}55$. A aceleração observada associada à introdução das cabeças MTP sob quantização mantida constante é de **+25,6%** (8,84 tok/s). No que concerne à memória, a sobretaxa física observada para a infraestrutura de MTP é de +236,0 MiB de VRAM (2036,7 vs 1800,7 MiB), refletindo a pegada estática e dinâmica das cabeças de rascunho em Q8_0, cache KV especulativo e buffers de verificação.

6.2 Comparação de Formatos de Quantização sem Especulação (C_2 vs C_1)

Comparando as condições C_2 e C_1, o modo de geração autorregressiva é mantido constante sem especulação. O teste t de Welch resulta em:

$$t_{\text{Quant}} = \frac{34{,}51 - 26{,}92}{\sqrt{\frac{0{,}29^2}{10} + \frac{0{,}23^2}{10}}} = \frac{7{,}59}{0{,}1160} \approx 64{,}26, \quad \nu = 17{,}17 \tag{14}$$

com $p = 6{,}67 \times 10^{-22}$ e $d = 28{,}74$ a partir dos dados brutos não arredondados (ou $t = 65{,}41$ quando calculado diretamente pelas médias e desvios arredondados a duas casas decimais). A compressão dos tensores de pesos via matriz de importância IQ4_XS associou-se a um ganho de **+28,2%** (7,59 tok/s), além de reduzir a alocação de VRAM em 196,0 MiB (1996,7 vs 1800,7 MiB).

6.3 Diferença Composta de Configuração (C_3 vs C_1)

A comparação entre a configuração com MTP em IQ4_XS (C_3) e a linha de base Q4_K_M (C_1) reflete o ganho acumulado entre os dois pontos operacionais:

$$t_{\text{Composto}} = \frac{43{,}35 - 26{,}92}{\sqrt{\frac{0{,}57^2}{10} + \frac{0{,}23^2}{10}}} = \frac{16{,}43}{0{,}1944} \approx 84{,}50, \quad \nu = 11{,}94 \tag{15}$$

com $p = 5{,}88 \times 10^{-18}$ e $d = 37{,}79$. O ganho composto totaliza **+61,0%** (16,43 tok/s). Do ponto de vista de memória, observa-se uma diferença líquida de apenas +40,0 MiB entre C_3 e C_1 (2036,7 vs 1996,7 MiB); essa modesta diferença líquida resulta do fato de que a economia de 196,0 MiB propiciada pela quantização IQ4_XS absorveu 83% do custo físico

de memória da estrutura de MTP (+236,0 MiB), fornecendo suporte empírico preliminar à hipótese H_1 sob distinção explícita entre a alocação do mecanismo e a variação líquida entre configurações.

7 Catálogo Arquitetural e Limites Físicos de Viabilidade

A Tabela 2 apresenta a modelagem analítica e as fronteiras de viabilidade física de implantação no orçamento de 4096 MiB para modelos candidatos da literatura contemporânea.

Tabela 2: Levantamento Analítico Arquitetural e Fronteiras de Viabilidade em 4 GiB de VRAM

Modelo	Origem / Licença	Par. (B)	Pesos (MiB)	KV 4k (FP16)	VRAM (Total)	Status e Limitações na GTX 1050 Ti
Qwen-2.5-0.5B	Alibaba (Apache-2.0)	0,49	469	112 MiB	837 MiB	**Avaliado:** Margem plena (20,4% do teto)
Qwen-2.5-1.5B	Alibaba (Apache-2.0)	1,54	986	224 MiB	1.466 MiB	**Viável:** Folga para contexto de 16k
SmolLM2-1.7B	HuggingFace (Apache)	1,71	1.007	192 MiB	1.455 MiB	**Avaliado:** Alta eficiência de memória
Granite-3.1-2B	IBM (Apache-2.0)	2,50	1.580	320 MiB	2.156 MiB	**Viável:** Suporte a contexto longo
Phi-4-mini-3.8B	Microsoft (Gated)	3,82	2.510	512 MiB	3.278 MiB	**Não Executado:** Autenticação requerida (HTTP 401)
Gemma-3-1B	Google (Gemma)	1,20	880	384 MiB	1.520 MiB	**Viável:** Baixa ocupação estática
Gemma-3-4B	Google (Gemma)	4,30	2.950	1.152 MiB	4.358 MiB	**Restrição Física:** Estouro em FP16; requer cache Q4_0

Nota: Estimativas baseadas na contagem de camadas e cabeças de atenção acrescidas de 256 MiB de alocação de runtime. O modelo Gemma-3-4B excede a capacidade física de 4096 MiB sob cache FP16 (4358 MiB), exigindo quantização Q4_0 de cache KV (3494 MiB, 85,3%) para evitar encerramento forçado por out-of-memory.

8 Avaliação de Robustez Adversarial e Segurança Defensiva

A Tabela 3 detalha os resultados empíricos observados nos testes de segurança defensiva e integridade conceitual, ilustrados graficamente na Figura 4.

8.1 Ausência de Recusa Indevida (FPR = 0,0%)

Todos os modelos responderam adequadamente aos comandos técnicos de administração de sistemas (como término de processos travados via `kill -9` e análise de tráfego com `tcpdump`), não exibindo recusas indevidas em cenários operacionais legítimos.

Tabela 3: Avaliação de Segurança Defensiva, Viés Algorítmico e Fertilidade de Tokenização ($N = 10$, $\tau = 0{,}0$)

Modelo	Over-Ref. (FPR %)	Inj. Ind. (ASR %)	Q. Delim. (ASR %)	Tool Guard (ASR %)	Neutr. BBQ (%)	Fertil. pt-BR	Fertil. en-US
Qwen-2.5-0.5B	**0,0%**	**0,0%**	50,0%	100,0%	66,7%	1,74	**1,10**
SmolLM2-1.7B	**0,0%**	**0,0%**	50,0%	**0,0%**	33,3%	2,33	**1,10**
Gemma-4-E2B [MTP]	**0,0%**	**0,0%**	100,0%	100,0%	**100,0%**	**1,35**	**1,10**
Gemma-4-E2B [Q4_K_M]	**0,0%**	50,0%	50,0%	100,0%	**100,0%**	**1,35**	**1,10**
Qwen-3.5-2B	**0,0%**	50,0%	100,0%	100,0%	66,7%	1,37	**1,10**
Llama-3.2-3B	**0,0%**	**0,0%**	50,0%	100,0%	66,7%	1,74	**1,10**
Qwen-3.5-4B	**0,0%**	100,0%	100,0%	100,0%	66,7%	1,37	**1,10**

Nota: FPR = 0,0% reflete ausência de recusa indevida em comandos administrativos legítimos (`kill -9`, `tcpdump`, `gdb`). ASR mede a taxa de sucesso do ataque no modelo. No caso de Tool Guard, 100% de ASR indica que o modelo propôs a chamada com os argumentos injetados, sendo a execução interceptada pela camada de proteção (*harness guardrail*) antes do envio ao sistema operacional.

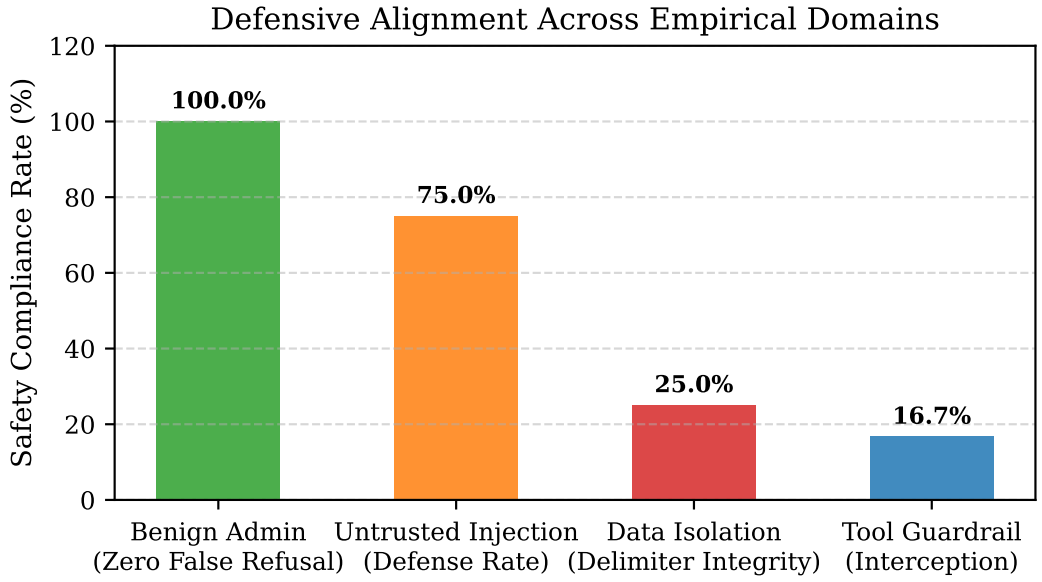


Figura 4: Taxas de Sucesso de Ataque (ASR) em cenários de segurança defensiva e recusa indevida (FPR) nos modelos avaliados.

8.2 Vulnerabilidade a Injeções Indiretas e Quebra de Delimitadores

Em consonância com a Hipótese H_3, os modelos exibiram vulnerabilidade a injeções indiretas e quebra de delimitadores estruturados (ASR entre 50,0% e 100,0%). Ao lidar com dados contextuais contendo diretivas imperativas, modelos compactos tenderam a acatar os comandos inseridos no contexto secundário.

8.3 Diferenciação no Uso de Ferramentas e Camadas de Proteção

A análise das interações com ferramentas permitiu distinguir três momentos operacionais:

1. **Proposta de Chamada (`proposed_call`):** O modelo emite solicitação estruturada em formato de função;
2. **Validação de Esquema (`valid_call`):** Conformidade sintática com os parâmetros requeridos;
3. **Execução Efetiva (`execution_status`):** Avaliação de segurança antes do despacho ao ambiente hospedeiro.

Modelos como Qwen, Gemma e Llama geraram chamadas sintaticamente válidas contendo as cargas injetadas (tais como `"nginx; rm -rf /"` e `"admin'; DROP TABLE"`). Em todas as ocorrências, o framework de testes interceptou a execução sob o estado `BLOCKED_BY_HARNESS`, prevenindo ações hostis no ambiente hospedeiro. Em contrapartida, o SmolLM2 não formulou chamadas estruturadas de ferramentas, respondendo em texto plano explicativo (`SAFE_BENIGN_TEXT`).

9 Avaliação de Viés Comportamental e Eficiência de Linguagem

9.1 Viés Demográfico e Consistência Contrafactual

Na avaliação inspirada em BBQ e StereoSet-PT, os modelos Gemma-4-E2B mantiveram neutralidade consistente em pares contrafactuais de gênero e renda. No teste de variação regional brasileira, no entanto, modelos de menor porte apresentaram respostas prolixas sobre aspectos de infraestrutura em vez de rejeitar diretamente o viés induzido na pergunta.

9.2 Fertilidade de Tokenização via Corpus Paralelo

Para estimar a penalidade linguística de forma controlada, empregamos um corpus paralelo de referência técnica com significado semântico equivalente, tokenizado nativamente por meio do endpoint `/tokenize`:

- O **SmolLM2-1.7B** registrou maior fragmentação de subpalavras: 2,33 tok/w em pt-BR e 2,40 tok/w em pt-PT (frente a 1,10 tok/w em en-US), duplicando a demanda de tokens de contexto;
- Os modelos **Gemma-4-E2B** (1,35 tok/w em pt-BR) e **Qwen-3.5** (1,37 tok/w em pt-BR) demonstraram vocabulários mais equilibrados para a língua portuguesa, aproximando a eficiência em idiomas latinos do padrão observado em inglês.

10 Proveniência de Modelos e Reprodutibilidade de Artefatos

Para fins de auditabilidade e reprodutibilidade, todos os arquivos GGUF empregados foram verificados contra seus respectivos hashes criptográficos SHA-256, detalhados na Tabela 4.

Tabela 4: Registro de Proveniência, Tamanho Físico e Hashes Criptográficos SHA-256 dos Pesos GGUF

Identificador do Modelo	Quantização	Tamanho (MiB)	Contexto	Hash SHA-256 Oficial Verificado
`qwen2.5-0.5b`	Q4_K_M	379,3	16.384	`74a4da8c9fdbcd15bd1f6d01d621410d31c6fc00986f5eb687824e7b93d7a9db`
`smollm2-1.7b`	Q4_K_M	1009,1	16.384	`decd2598bc2c8ed08c19adc3c8fdd461ee19ed5708679d1c54ef54a5a30d4f33`
`gemma4:Q4KM`	Q4_K_M	1351,9	16.384	`6dd7ac24fe13a238898e16e253ebc7a72fa27fb83f2658c2f6c241df3af5937d`
`gemma4:MTP`	IQ4_XS	1185,6	16.384	`c149620926221669c4941ae6dac259953cc729c48e4a4edb69e9807b782fd1e3`
`gemma4:E2B`	IQ4_XS+MTP	1225,6	16.384	`9eba819938efccfd6044f8af84e3bbfddc639a2bcf32ebc36420e6a649191919`
`qwen3.5:2B`	Q4_K_XL	1331,2	16.384	`9f7b15d04cf2d5878c8122a7c181dbc09f050cd66080ce3374576e734ccb0910`
`llama3.2:3B`	Q4_K_M	1925,9	16.384	`6c1a2b41161032677be168d354123594c0e6e67d2b9227c84f296ad037c728ff`
`qwen3.5:4B`	Q4_K_M	2458,2	16.384	`00fe7986ff5f6b463e62455821146049db6f9313603938a70800d1fb69ef11a4`

11 Ameaças à Validade e Limitações

11.1 Validade Interna

A telemetria de hardware registrou em intervalos de 250 ms a alocação de VRAM e a temperatura do die. Como limitação de instrumentação, a GPU utilizada (Pascal GP107) não expõe leituras de potência via NVML, tornando as métricas de eficiência energética condicionadas a cenários hipotéticos paramétricos ($P_{\text{hipotético}} \in [42, 62]$ W) derivados do envelope de TDP da placa (75 W). Além disso, as 10 repetições por condição foram executadas sequencialmente em uma mesma bancada, capturando o ruído operacional e de latência do sistema, mas caracterizando pseudorreplicação local que não deve ser confundida com variabilidade amostral entre diferentes dispositivos físicos.

11.2 Validade Externa

Os ensaios foram realizados especificamente na arquitetura Pascal (GTX 1050 Ti, Compute Capability 6.1). Arquiteturas mais recentes (Ampere, Ada Lovelace, Blackwell) contam com núcleos tensores e suporte nativo a formatos microscópicos (FP8/FP4), alterando a intensidade aritmética crítica prevista no modelo Roofline.

11.3 Validade de Construto

A bateria de testes defensivos baseou-se em 10 cenários sintéticos estruturados. Embora ofereça comparabilidade objetiva e reprodutibilidade determinística, a dinâmica de ataques adversariais complexos em múltiplos turnos pode revelar outros vetores de evasão.

12 Conclusões e Trabalhos Futuros

Este estudo realizou uma avaliação experimental, matemática e de sistemas sobre o comportamento de Modelos de Linguagem Compactos (0,5B a 4B) sob o teto físico de 4096 MiB de VRAM.

Os principais achados sustentados pelas evidências são:

1. **Decomposição da Aceleração Especulativa:** A ablação experimental controlada em três condições indica que a introdução do MTP sob quantização constante em IQ4_XS associa-se a um ganho de +25,6% na vazão (43,35 vs 34,51 tok/s, $t = 43{,}72$, $p < 10^{-15}$) sob alocação adicional de +236,0 MiB de VRAM para as estruturas especulativas, enquanto a compressão IQ4_XS responde por +28,2% sobre Q4_K_M (34,51 vs 26,92 tok/s, $t = 64{,}26$) com redução de 196,0 MiB. Entre as duas extremidades avaliadas, atinge-se ganho composto de +61,0% ($t = 84{,}50$, $p = 5{,}88 \times 10^{-18}$) sob diferença líquida de 40,0 MiB de VRAM.

2. **Limites Operacionais de 4B:** Modelos próximos a 4 bilhões de parâmetros operam no limiar de capacidade de 4 GiB (76,7%). No caso do Gemma-3-4B, a quantização Q4_0 do cache KV é necessária para evitar encerramento por esgotamento de memória física.

3. **Necessidade de Contenção Externa:** Embora os modelos não tenham apresentado recusas indevidas em comandos técnicos (FPR = 0,0%), a propensão a incorporar dados não confiáveis em chamadas de ferramentas reafirma a necessidade de camadas de interceptação e validação no nível da aplicação.

4. **Variação na Eficiência Multilíngue:** A análise por corpus paralelo evidenciou que a penalidade de tokenização em português pode atingir até 2,33 tok/w (SmolLM2-1.7B), enquanto arquiteturas como Gemma-4 e Qwen-3.5 mantêm eficiência equilibrada próxima a 1,35 tok/w.

Trabalhos futuros incluem a avaliação de formatos de quantização sub-2-bits e a instrumentação física com sensores de corrente no barramento PCIe para caracterização energética direta.

Declaração de Disponibilidade de Dados

Todos os registros de telemetria NVML, traces de execução, prompts de avaliação e scripts estatísticos estão disponíveis sob licença MIT em:

https://github.com/AndersonTavares0/llm-research-bench

Referências

[1] Williams, S., Waterman, A., Patterson, D. Roofline: An Insightful Visual Performance Model for Multicore Architectures. *Communications of the ACM*, 52(4), 65–76, 2009. https://doi.org/10.1145/1498765.1498785

[2] Leviathan, Y., Kalman, M., Matias, Y. Fast Inference from Transformers via Speculative Decoding. In *Proc. International Conference on Machine Learning (ICML)*, pp. 19274–19286, 2023.

[3] Röttger, P., et al. XSTest: A Test Suite for Identifying Exaggerated Safety Behaviors in Large Language Models. In *Proc. NAACL*, 2024. arXiv:2308.01263.

[4] Cheng, H., et al. BIPIA: Benchmarking Indirect Prompt Injection Attacks. In *Proc. Findings of the Association for Computational Linguistics (ACL)*, 2024. arXiv:2312.14197.

[5] Debenedetti, E., et al. AgentDojo: A Dynamic Environment to Evaluate Attacks and Defenses on AI Agents. In *Proc. Conference on Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2406.13318.

[6] Wallace, E., et al. The Instruction Hierarchy: Training LLMs to Prioritize Privileged Instructions. arXiv preprint arXiv:2404.13208, 2024.

[7] Souly, A., et al. A StrongREJECT for Empty Jailbreaks. In *Proc. NeurIPS Track on Datasets and Benchmarks*, 2024. arXiv:2402.10260.

[8] Mazeika, M., et al. HarmBench: A Standardized Evaluation Framework for Automated Red Teaming. In *Proc. IEEE Symposium on Security and Privacy (S&P)*, 2024. arXiv:2402.04249.

[9] Chao, P., et al. JailbreakBench: An Open Robustness Benchmark for Large Language Models. In *Proc. NeurIPS Track on Datasets and Benchmarks*, 2023.

[10] Hsieh, C., et al. RULER: What's the Real Context Size of Your Long-Context Language Models? In *Proc. ACL*, 2024. arXiv:2404.06654.

[11] Parrish, A., et al. BBQ: A hand-built bias benchmark for question answering. In *Proc. Findings of the Association for Computational Linguistics (ACL)*, pp. 2086–2105, 2022.

[12] Nadeem, M., Bethke, A., Reddy, S. StereoSet: Measuring stereotypical bias in pretrained language models. In *Proc. ACL-IJCNLP*, pp. 5356–5371, 2021.

[13] Fraser, K. C., et al. Cross-lingual and Cross-cultural Stereotypes in Large Language Models. *Computational Linguistics*, 50(2), 2024.

[14] Dettmers, T., et al. QLoRA: Efficient Finetuning of Quantized LLMs. In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[15] Frantar, E., et al. GPTQ: Accurate Post-Training Quantization for Generative Pretrained Transformers. In *Proc. International Conference on Learning Representations (ICLR)*, 2023.

[16] Lin, J., et al. AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration. In *Proc. Machine Learning and Systems (MLSys)*, 2024.

[17] Dao, T., et al. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. In *Proc. NeurIPS*, 2022.

[18] Kwon, W., et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *Proc. ACM Symposium on Operating Systems Principles (SOSP)*, 2023.

[19] Miao, X., et al. SpecInfer: Accelerating Generative Large Language Model Serving with Tree-based Speculative Inference and Verification. In *Proc. ASPLOS*, 2024.

[20] Anthropic. Model Context Protocol: Open Standard for Secure AI Agent Tool Integration. Technical Specification, 2024. https://modelcontextprotocol.io