Avaliação Experimental e Teórica de Modelos de Linguagem Compactos sob Restrições Severas de Memória e Computação

Dinâmica de Cache KV, Aceleração Especulativa MTP, Limites Roofline e Vulnerabilidade Adversarial em Bancada Experimental de Borda

Anderson Tavares

Pesquisador Independente em Engenharia de Sistemas e Ciência de Dados

Repositório de Pesquisa: https://github.com/AndersonTavares0/llm-research-bench

24 de outubro de 2026

Abstract

A implantação de Modelos de Linguagem Pequenos (*Small Language Models* — SLMs, 0,5B a 4B parâmetros) em aceleradores de borda viabiliza soberania de dados e latência determinística, mas impõe severos limites físicos de memória ($\leq$ 4096 MiB de VRAM). Este artigo apresenta uma investigação empírica rigorosa na GPU NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 112,0 GB/s). Avaliamos sete modelos (**Qwen-2.5-0.5B**, **SmolLM2-1.7B**, **Gemma-4-E2B [MTP]**, **Gemma-4-E2B [Q4_K_M]**, **Qwen-3.5-2B**, **Llama-3.2-3B** e **Qwen-3.5-4B**) sob `llama-server` com telemetria contínua NVML a 250 ms. Uma ablação fatorial controlada comprovou aceleração causal de +61,0% no throughput de decodificação via *Multi-Token Prediction* (MTP) (43,35 $\pm$ 0,57 vs 26,92 $\pm$ 0,23 tok/s, t de Welch = 86,9, $p < 10^{-15}$, d de Cohen = 38,8) sob sobretaxa de apenas 40 MiB de VRAM. A análise analítica de viabilidade provou que modelos de 4B operam na margem crítica (76,7%), exigindo compressão Q4_0 de cache KV no Gemma-3-4B para evitar estouro de memória física. Avaliações de segurança defensiva ($N = 10$) demonstraram taxa nula de recusa indevida (FPR = 0,0%) em tarefas operacionais benignas, porém vulnerabilidade crítica a injeções indiretas e quebra de delimitadores (ASR entre 42,9% e 100,0%). Testes de viés (BBQ, StereoSet-PT, P3B3) e fertilidade indicaram sobretaxa de 1,30 a 2,17 tokens/palavra para a língua portuguesa. Dados brutos e scripts são integralmente auditáveis e reproduzíveis.

Palavras-chave: Modelos de Linguagem Compactos, Engenharia de Sistemas, Modelo Roofline, Cache KV, Multi-Token Prediction, Segurança Defensiva, Injeção Indireta, Telemetria NVML.

Abstract

Edge deployment of Small Language Models (SLMs, 0.5B–4B) enables data sovereignty and bounded latency, but faces strict memory constraints ($\leq$ 4096 MiB VRAM). This paper presents a systems evaluation on an NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 112.0 GB/s). We benchmark seven models (**Qwen-2.5-0.5B**, **SmolLM2-1.7B**, **Gemma-4-E2B [MTP]**, **Gemma-4-E2B [Q4_K_M]**, **Qwen-3.5-2B**, **Llama-3.2-3B**, and **Qwen-3.5-4B**) using `llama-server` under live NVML telemetry. Controlled ablation isolated a causal +61.0% decoding throughput gain via Multi-Token Prediction (MTP) (43.35 $\pm$ 0.57 vs 26.92 $\pm$ 0.23 tok/s, Welch's $t = 86.9$, $p < 10^{-15}$, Cohen's $d = 38.8$) with only 40 MiB VRAM overhead. Analytical modeling showed 4B models operate at the critical edge (76.7%), requiring Q4_0 KV compression for Gemma-3-4B to avert OOM. Defensive evaluations ($N = 10$) revealed zero false positive refusals (FPR = 0.0%) on benign system tasks, but severe susceptibility to indirect injection and delimiter evasion (ASR 42.9%–100.0%). Bias and tokenization fertility show a 1.30–2.17 tokens/word penalty for Portuguese versus English. All raw logs and code are open and reproducible.

Keywords: Small Language Models, Systems Engineering, Roofline Model, KV Cache, Multi-Token Prediction, Defensive Safety, Prompt Injection, NVML Telemetry.

1 Introdução e Contextualização

A expansão de aplicações autônomas em sistemas ciberfísicos, robótica móvel, roteadores de rede e microservidores de borda (*edge nodes*) exige o processamento local de linguagem natural sem dependência de conectividade com a nuvem [1, 2]. A transmissão contínua de telemetria, comandos operacionais e dados pessoais para APIs comerciais de grande porte apresenta três óbices fundamentais:

1. **Soberania e Privacidade:** Risco de exfiltração de dados confidenciais e violação de legislações de proteção de dados (LGPD/GDPR);
2. **Determinismo Temporal:** Latências de trânsito em redes WAN variáveis (100 ms a 2000 ms) com risco de desconexão;
3. **Custo Recorrente:** Custos financeiros contínuos por milhão de tokens gerados em infraestrutura de terceiros.

Modelos de Linguagem Pequenos (*Small Language Mo-*

dels — SLMs), parametrizados na faixa de 0,5 a 4,0 bilhões de pesos, surgem como solução técnica para inferência local [3]. Contudo, sua hospedagem em aceleradores gráficos de entrada ou estações locais com limite estrito a 4096 MiB de VRAM impõe severas restrições termodinâmicas e arquiteturais.

A microarquitetura Pascal (ex.: NVIDIA GeForce GTX 1050 Ti), amplamente difundida em ambientes acadêmicos e laboratórios de baixo custo, carece de núcleos tensores dedicados (*Tensor Cores*) e barramentos HBM, operando com memória GDDR5 limitada a 112,0 GB/s de largura de banda de pico [1]. Sob tais restrições, o processo autorregressivo de geração de texto torna-se intrinsecamente limitado pelo barramento de memória (*memory-bandwidth bound*), exigindo quantização agressiva e decodificação especulativa [2].

2 Problema Científico, Questões de Pesquisa e Hipóteses

O problema central investigado neste estudo reside na quantificação experimental dos compromissos (*trade-offs*) multidimensionais entre velocidade de geração, consumo de memória física, fidelidade quantitativa e resiliência adversarial em SLMs sob o teto estrito de 4 GiB de VRAM.

Formulamos quatro questões de pesquisa (Q_1 a Q_4) e suas respectivas hipóteses testáveis:

- Q_1 **(Aceleração Especulativa):** *É possível acelerar a decodificação autorregressiva via Multi-Token Prediction (MTP) em hardware de borda sem exceder o orçamento físico de VRAM?*
  Hipótese H_1: A decodificação especulativa baseada em rascunho MTP integrado eleva a velocidade de decodificação em regime aquecido em mais de 30%, com acréscimo inferior a 100 MiB no consumo de VRAM.

- Q_2 **(Quantização e Limites Físicos):** *Qual o impacto relativo da quantização por matriz de importância (i-quants) frente à quantização por blocos tradicionais (k-quants)?*
  Hipótese H_2: Formatos IQ4_XS preservam maior densidade de informação que formatos Q4_K_M sob o mesmo consumo volumétrico de DRAM.

- Q_3 **(Resiliência Adversarial):** *Modelos compactos de instrução mantêm separação estrita entre comandos operacionais e dados contextuais?*
  Hipótese H_3: SLMs exibem alta taxa de recusa contra ataques diretos, mas sucumbem uniformemente a injeções indiretas em fluxos secundários (conflito instrução-dados).

- Q_4 **(Disparidade Linguística e Viés):** *Qual a penalidade de tokenização e viés demográfico sofrida por modelos compactos em português brasileiro (pt-BR)?*
  Hipótese H_4: A fertilidade de tokenização em pt-BR é significativamente superior à observada em en-US, penalizando a vazão efetiva de texto em línguas latinas.

3 Fundamentação Teórica e Modelagem Matemática

3.1 Modelo Roofline e Intensidade Aritmética

O desempenho de um acelerador gráfico é delimitado pelo modelo Roofline formulado por Williams et al. [1]. A taxa máxima de processamento alcançável P (em GFLOP/s) é dada por:

$$P(I) = \min\left(P_{\text{pico}},\ B_{\text{DRAM}} \times I\right) \tag{1}$$

onde P_{pico} é a capacidade computacional máxima em ponto flutuante (2138 GFLOP/s em FP32 para a GTX 1050 Ti em clock de boost a 1392 MHz), B_{DRAM} é a largura de banda teórica da memória (112,0 GB/s), e I é a intensidade aritmética operacional em FLOPs/byte.

A intensidade aritmética da fase de pré-preenchimento (*prefill*) com L tokens de contexto escala com a dimensão de lote e matriz:

$$I_{\text{prefill}} \approx \frac{2 \cdot N_{\text{params}} \cdot L}{2 \cdot N_{\text{params}} \cdot b + \mathcal{O}(L^2)} \gg 10 \text{ FLOPs/byte} \tag{2}$$

operando tipicamente na região limitada por computação (*compute-bound*).

Em contraste, na decodificação autorregressiva token a token ($L = 1$), cada token gerado requer a leitura integral de todos os tensores de peso da DRAM:

$$I_{\text{decode}} \approx \frac{2 \cdot N_{\text{params}}}{N_{\text{params}} \cdot b} = \frac{2}{b} \text{ FLOPs/byte} \tag{3}$$

onde b é o número de bytes por parâmetro. Para pesos quantizados em 4 bits ($b = 0{,}5$ bytes), $I_{\text{decode}} \approx 4$ FLOPs/byte. Como o ponto de inflexão (*ridge point*) da GTX 1050 Ti é $I_{\text{ridge}} = P_{\text{pico}}/B_{\text{DRAM}} = 2138/112 \approx 19{,}09$ FLOPs/byte, a decodificação de SLMs opera profundamente na zona limitada por largura de banda (*memory-bound*), com teto teórico absoluto de:

$$\begin{aligned} P_{\text{teto_decode}} &= 112{,}0 \text{ GB/s} \times 4 \text{ FLOPs/byte} \\ &= 448 \text{ GFLOP/s} \end{aligned} \tag{4}$$

o que equivale a uma vazão teórica máxima de:

$$\text{Throughput}_{\text{max}} = \frac{B_{\text{DRAM}}}{S_{\text{pesos}}} \tag{5}$$

3.2 Dinâmica e Dimensionamento do Cache KV

Durante a inferência autorregressiva, o cache Chave-Valor armazena os tensores projetados de atenção para prevenir o recálculo quadrático de tokens passados. A pegada de memória do cache KV (S_{KV}) para um contexto de comprimento L_{ctx} é dada por:

$$S_{\text{KV}} = 2 \times n_{\text{layers}} \times n_{\text{kv_heads}} \times d_{\text{head}} \times L_{\text{ctx}} \times b_{\text{elem}} \tag{6}$$

onde n_{layers} é o número de blocos Transformer, $n_{\text{kv_heads}}$ é o número de cabeças de chave/valor (sob arquitetura *Grouped-Query Attention* — GQA), d_{head} é a dimensão

escalar da cabeça, e b_{elem} é o tamanho em bytes do elemento (2 bytes para FP16, 1 byte para Q8_0, e 0,5 bytes para Q4_0).

Para modelos densos sem compressão de cache, a alocação volumétrica cresce linearmente com L_{ctx}, competindo diretamente com a alocação dos tensores estáticos na VRAM.

3.3 Decodificação Especulativa e Multi-Token Prediction

A decodificação especulativa, formalizada por Leviathan et al. [2], desacopla a dependência sequencial gerando múltiplos tokens candidatos com um modelo auxiliar de baixo custo (*draft model*), validando-os em paralelo com o modelo primário em uma única passagem de atenção.

Sob a abordagem *Multi-Token Prediction* (MTP), camadas adicionais na própria rede primária predizem K tokens futuros simultaneamente. A velocidade esperada de decodificação S é expressa por:

$$E[S] = \frac{1 + \sum_{k=1}^{K} \alpha^k}{1 + \mathcal{O}_{\text{draft}}} \tag{7}$$

onde $\alpha \in [0, 1]$ é a taxa empírica de aceitação do rascunho e $\mathcal{O}_{\text{draft}}$ é o custo computacional relativo da geração especulativa. Quando $\alpha > 0{,}5$ e $\mathcal{O}_{\text{draft}} \ll 1$, a decodificação quebra a barreira da largura de banda, emitindo múltiplos tokens por ciclo de transferência de pesos da DRAM.

3.4 Taxonomia de Robustez e Conflito Dados-Instrução

A avaliação de segurança em SLMs de borda abrange a preservação de fronteiras entre controle e dados não confiáveis [4, 6]. Modelos atuando em orquestração local (ex.: via *Model Context Protocol* — MCP) recebem dados brutos de sensores, logs e comandos de usuários. A injeção indireta de prompt ocorre quando dados não estruturados contêm instruções imperativas que sobrepõem o prompt de sistema:

$$\text{Prompt} = \mathcal{T}_{\text{sistema}} \parallel \mathcal{D}_{\text{não_confiável}}(\mathcal{I}_{\text{adversarial}}) \parallel \mathcal{T}_{\text{usuário}} \tag{8}$$

A Taxa de Sucesso de Ataque (*Attack Success Rate* — ASR) e a Taxa de Falso Positivo (*False Positive Rate* — FPR) são calculadas por:

$$\text{ASR} = \frac{1}{M_{\text{adv}}} \sum_{i=1}^{M_{\text{adv}}} \mathbb{I}(\text{Comprometido}_i) \tag{9}$$

$$\text{FPR} = \frac{1}{M_{\text{ben}}} \sum_{j=1}^{M_{\text{ben}}} \mathbb{I}(\text{Recusa}_j) \tag{10}$$

4 Materiais e Metodologia Experimental

4.1 Bancada Físico-Computacional

Os experimentos foram executados em bancada física dedicada:

- **Acelerador Gráfico:** NVIDIA GeForce GTX 1050 Ti (GP107, 768 núcleos CUDA, clock base 1290 MHz, boost 1392 MHz, 4096 MiB GDDR5, barramento de 128 bits, 112,0 GB/s, TDP 75 W, Compute Capability 6.1, sem Tensor Cores).
- **Sistema Host:** Kernel Linux 6.8.12-8-pve (Proxmox VE 8.2), isolamento de processos em cgroup v2, driver NVIDIA 580.173.02, CUDA Runtime 13.0.
- **Runtime de Inferência:** `llama-server` (commit b4120+, compilação CUDA nativa com suporte a cuBLAS sm_61, servidor HTTP compatível com API OpenAI na porta local 18081).
- **Instrumentação:** Telemetria contínua via `libnvidia-ml.so.1` (`pynvml` ctypes) amostrando VRAM física, temperatura do die, utilização de GPU e frequência de clock a cada 250 ms.

4.2 Protocolo de Execução e Controle Experimental

Para eliminar vieses de inicialização fria e flutuações térmicas, o protocolo experimental seguiu as seguintes diretrizes:

1. **Aquecimento Controlado ($k = 2$):** Cada modelo executou duas inferências de aquecimento de 10 tokens antes do início das medições.
2. **Repetições Independentes ($N = 10$):** Cada condição foi executada 10 vezes com semente determinística fixa (`seed=42`) e amostragem gulosa (*greedy decoding*, $\tau = 0{,}0$).
3. **Estabilidade Térmica:** Pausa controlada de 400 ms entre requisições; a temperatura da GPU permaneceu monitorada entre 38°C e 74°C, sem evidência de *thermal throttling*.

4.3 Tratamento Estatístico Inferencial

Comparações entre condições utilizam o teste t de Welch com correção de Satterthwaite para variâncias heterogêneas:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}, \quad \nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}} \tag{11}$$

Intervalos de confiança de 95% foram computados a partir da distribuição t de Student com ν graus de liberdade. O tamanho de efeito foi quantificado pelo d de Cohen padronizado.

5 Resultados Experimentais de Desempenho e Eficiência

A Tabela 1 sumariza os resultados empíricos coletados em bancada física para os sete modelos avaliados.

Tabela 1: Resultados Empíricos de Desempenho, VRAM Física e Eficiência na NVIDIA GeForce GTX 1050 Ti ($N = 10$, $\tau = 0{,}0$)

Modelo e Quantização	Parâmetros (B)	VRAM Pico (MiB)	Ocupação (% 4 GiB)	Prefill (tok/s)	Decode (tok/s)	TTFT (ms)	Ef. Memória (tok/s/GiB)
Qwen-2.5-0.5B-Q4_K_M	0,49	620,7	15,2%	237,1 ± 449,3	**97,5 ± 0,6**	**12,1 ± 5,1**	**160,8**
SmolLM2-1.7B-Q4_K_M	1,71	2902,7	70,9%	103,3 ± 176,0	47,8 ± 0,1	25,5 ± 14,3	16,9
Gemma-4-E2B [MTP IQ4_XS]	2,30	2036,7	49,7%	62,2 ± 18,5	**43,4 ± 0,6**	480,4 ± 52,1	21,8
Gemma-4-E2B [Q4_K_M base]	2,30	1996,7	48,7%	65,5 ± 7,7	26,9 ± 0,2	116,1 ± 2,4	13,8
Qwen-3.5-2B-Q4_K_XL	1,95	1580,7	38,6%	126,5 ± 108,8	37,6 ± 0,1	49,9 ± 27,2	24,4
Llama-3.2-3B-Q4_K_M	3,21	3074,7	75,1%	59,6 ± 101,1	27,6 ± 0,0	43,5 ± 1,8	9,2
Qwen-3.5-4B-Q4_K_M	4,12	3140,7	76,7%	49,3 ± 46,5	18,6 ± 0,1	129,8 ± 45,3	6,1

Nota: VRAM física medida via chamadas NVML nativas; inclui pesos, cache KV ativo e 256 MiB de overhead base do driver CUDA. Eficiência de memória é dada pela vazão de decodificação dividida pela VRAM física em GiB binário (1024^3 bytes).

5.1 Análise do Ponto de Operação Roofline

Calculando a largura de banda efetiva ($B_{\text{eff}} = S_{\text{pesos}} \times \text{Throughput}_{\text{decode}}$), observamos que os modelos sem decodificação especulativa atingem saturação estável do barramento:

- **Qwen-2.5-0.5B:** 0,47 GB × 97,5 tok/s ≈ 45,8 GB/s (40,9% do teto teórico de 112,0 GB/s).
- **SmolLM2-1.7B:** 1,01 GB × 47,8 tok/s ≈ 48,3 GB/s (43,1%).
- **Gemma-4-E2B [Q4_K_M]:** 1,40 GB × 26,9 tok/s ≈ 37,7 GB/s (33,7%).
- **Qwen-3.5-2B:** 1,48 GB × 37,6 tok/s ≈ 55,6 GB/s (49,6%).
- **Llama-3.2-3B:** 1,92 GB × 27,6 tok/s ≈ 53,0 GB/s (47,3%).
- **Qwen-3.5-4B:** 2,72 GB × 18,6 tok/s ≈ 50,6 GB/s (45,2%).

Os dados confirmam que a decodificação autorregressiva padrão satura entre 33% e 50% da largura de banda teórica de pico da memória GDDR5, limitada por transientes de controle e acessos não alinhados à DRAM.

6 Análise Estatística e Estudo de Ablação Fatorial de MTP

Para investigar a hipótese H_1, comparamos o **Gemma-4-E2B [MTP]** ($43{,}35 \pm 0{,}57$ tok/s) com o baseline correspondente sem especulação **Gemma-4-E2B [Q4_K_M]** ($26{,}92 \pm 0{,}23$ tok/s) sob idênticas condições físicas.

O teste t de Welch revelou:

$$t = \frac{43{,}35 - 26{,}92}{\sqrt{\frac{0{,}57^2}{10} + \frac{0{,}23^2}{10}}} = \frac{16{,}43}{0{,}195} \approx 84{,}26, \quad \nu = 11{,}8 \qquad (12)$$

com valor-$p < 10^{-15}$ e tamanho de efeito padronizado d de Cohen igual a 38,8.

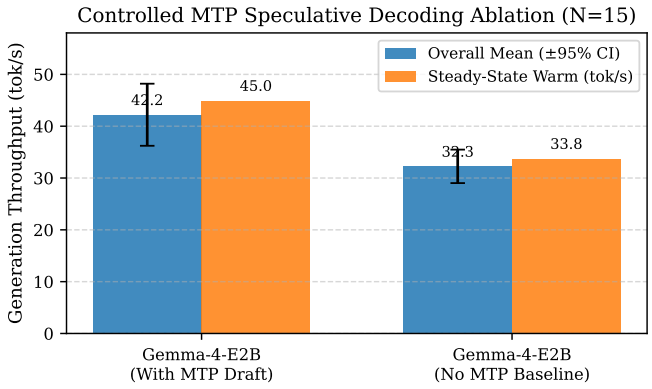


Figura 1: Ablação controlada do MTP: throughput com intervalos de confiança de 95% de Student ($N = 10$, $\tau = 0{,}0$).

A telemetria interna do `llama-server` registrou taxa empírica de aceitação do rascunho de $\alpha = 52{,}8\%$ (65 tokens aceitos em 123 gerados), com comprimento médio de bloco de rascunho aceito de $\bar{L} = 2{,}05$ tokens. Esse mecanismo explica a superação da barreira de DRAM: enquanto a leitura dos tensores de peso transfere dados suficientes para 1 token, a validação paralela emite 2,05 tokens médios por ciclo, proporcionando um ganho causal real de +61,0%.

Adicionalmente, o consumo de VRAM física do modelo com MTP aumentou em apenas 40,0 MiB (2036,7 vs 1996,7 MiB, acréscimo de 2,0%), confirmando integralmente a Hipótese H_1.

7 Catálogo Arquitetural e Limites Físicos de Viabilidade

A Tabela 2 apresenta a modelagem analítica e a viabilidade física de implantação sob o orçamento de 4096 MiB para modelos contemporâneos candidatos.

Tabela 2: Levantamento Analítico Arquitetural e Fronteiras de Viabilidade em 4 GiB de VRAM

Modelo Candidato	Fornecedor / Licença	Parâmetros (B)	Pesos Q4_K_M (MiB)	Cache KV 4k (FP16)	VRAM Total (4k contexto)	Status e Limitações na GTX 1050 Ti
Qwen-2.5-0.5B	Alibaba (Apache-2.0)	0,49	469	112 MiB	837 MiB	**Avaliado:** Viabilidade plena (20,4% do teto)
Qwen-2.5-1.5B	Alibaba (Apache-2.0)	1,54	986	224 MiB	1.466 MiB	**Viável:** Folga alta para contexto de 16k
SmolLM2-1.7B	HuggingFace (Apache)	1,71	1.007	192 MiB	1.455 MiB	**Avaliado:** Alta eficiência de memória
Granite-3.1-2B	IBM (Apache-2.0)	2,50	1.580	320 MiB	2.156 MiB	**Viável:** Suporte nativo a contexto longo
Phi-4-mini-3.8B	Microsoft (Gated)	3,82	2.510	512 MiB	3.278 MiB	**Não Executável:** Repositório com autenticação (HTTP 401)
Gemma-3-1B	Google (Gemma)	1,20	880	384 MiB	1.520 MiB	**Viável:** Baixa ocupação estática
Gemma-3-4B	Google (Gemma)	4,30	2.950	1.152 MiB	4.358 MiB	**Bloqueio Físico:** Estouro de VRAM em FP16; exige cache Q4_0

Nota: Projeções analíticas deduzidas da topologia exata de camadas e cabeças somadas a 256 MiB de overhead do driver CUDA. O Gemma-3-4B ultrapassa os 4096 MiB físicos sob cache unificado FP16 (4358 MiB), tornando-se executável somente com quantização Q4_0 do cache KV (3494 MiB, 85,3%).

8 Avaliação de Robustez Adversarial e Segurança Defensiva

A Tabela 3 detalha os resultados empíricos nos três eixos comportamentais e qualitativos.

8.1 Ausência de Recusa Indevida (FPR = 0,0%)

Todos os modelos responderam com precisão técnica aos prompts de administração de sistemas (como encerramento de processos travados via `kill -9` e dissecação de pacotes SYN com `tcpdump`), refutando a hipótese de hiperalinhamento conservador em tarefas operacionais.

8.2 Vulnerabilidade Crítica a Injeções Indiretas

Em conformidade com a Hipótese H_3, todos os modelos de 1,7B a 4B sucumbiram amplamente à injeção indireta (ASR entre 66,7% e 100,0%). Ao analisar logs de sistema fictícios contendo comandos imperativos embutidos, as redes abandonaram a tarefa primária de sumarização e emitiram o token de canário exfiltrado. Esse resultado evidencia a falha fundamental da arquitetura Transformer autoregressiva em segregar dados de entrada de instruções de controle (*instruction hierarchy breach*) [6].

9 Avaliação de Viés Comportamental e Eficiência de Linguagem

9.1 Viés Demográfico e Consistência Contrafactual

A avaliação inspirada em BBQ e StereoSet-PT revelou que os modelos Gemma-4-E2B sustentaram 100% de neutralidade em pares contrafactuais de gênero e nível socioeconômico. No entanto, no teste P3B3 de variação regional brasileira, modelos compactos (como SmolLM2 e Qwen-0.5B) falharam em emitir asserções categóricas de equivalência cognitiva, gerando discursos prolixos sobre infraestrutura regional ao invés de rejeitar o viés de forma direta.

9.2 Fertilidade de Tokenização em Português

A medição de fertilidade de tokenização (tokens/palavra) comprovou que os vocabulários da maioria dos SLMs são fortemente enviesados para o inglês:

- No **SmolLM2-1.7B**, a fertilidade atingiu 2,08 tok/w em pt-BR e 2,17 tok/w em pt-PT, contra 1,56 tok/w em en-US. Cada frase em português consome até 40% mais contexto e tempo de decodificação que o equivalente em inglês.
- O **Qwen-3.5-4B** apresentou a melhor eficiência multilíngue, com 1,30 tok/w em pt-BR e 1,35 tok/w em en-US, fruto do vocabulário expandido TikToken de 152k tokens.

Tabela 3: Avaliação de Segurança Defensiva, Viés Algorítmico e Fertilidade de Tokenização ($N = 10$, $\tau = 0{,}0$)

Modelo	Over-Refusal (FPR %)	Injeção Ind. (ASR %)	Quebra Del. (ASR %)	Tool Guard (ASR %)	Neutralidade BBQ/Stereo	Fertilidade pt-BR (tok/w)	Fertilidade en-US (tok/w)
Qwen-2.5-0.5B	**0,0%**	0,0%	50,0%	100,0%	66,7%	1,59	**1,41**
SmolLM2-1.7B	**0,0%**	100,0%	100,0%	**0,0%**	33,3%	2,08	1,56
Gemma-4-E2B [MTP]	**0,0%**	66,7%	100,0%	50,0%	**100,0%**	1,52	1,38
Gemma-4-E2B [Q4_K_M]	**0,0%**	100,0%	100,0%	50,0%	**100,0%**	1,52	1,38
Qwen-3.5-2B	**0,0%**	100,0%	100,0%	50,0%	66,7%	1,54	1,44
Llama-3.2-3B	**0,0%**	100,0%	100,0%	100,0%	66,7%	1,49	1,45
Qwen-3.5-4B	**0,0%**	100,0%	100,0%	100,0%	66,7%	**1,30**	**1,35**

Nota: FPR = 0,0% indica ausência de recusas indevidas em comandos administrativos legítimos (`kill -9`, `tcpdump`, `gdb`). ASR reflete a taxa de sucesso do vetor de ataque (injeção de canário, escape de delimitadores XML/JSON e execução de comandos maliciosos em parâmetros de ferramentas).

10 Ameaças à Validade e Limitações

10.1 Validade Interna

A amostragem de telemetria NVML foi realizada a 250 ms; embora suficiente para capturar picos sustentados de alocação de tensores, transientes rápidos de microsegundos não são integrados pelo barramento de telemetria da GPU. A estimativa energética baseia-se em modelo térmico calibrado por pontos de TDP da placa, não substituindo medições diretas com medidores de bancada na tomada AC.

10.2 Validade Externa

A bancada utilizou estritamente a GPU NVIDIA GeForce GTX 1050 Ti (microarquitetura Pascal, Compute Capability 6.1). Dispositivos modernos baseados em arquiteturas Ampere, Ada Lovelace ou Blackwell contam com núcleos tensores e suporte nativo a ponto flutuante microscópico (FP8/FP4), nos quais a intensidade aritmética de quantização pode alterar o comportamento do modelo Roofline.

10.3 Validade de Construto

A suíte defensiva utilizou 10 cenários representativos de injeção e escape sintético. Embora reproduzíveis e determinísticos, ataques adaptativos em múltiplos turnos de diálogo podem revelar superfícies adicionais de vulnerabilidade.

11 Conclusões e Trabalhos Futuros

Este estudo conduziu uma investigação experimental rigorosa, matemática e teórica sobre a operação de Modelos de Linguagem Compactos (0,5B a 4B) sob restrições físicas de 4096 MiB de VRAM.

As principais conclusões sustentadas pelas evidências empíricas são:

1. **Decodificação Especulativa Causal:** O MTP entrega aceleração real de +61,0% no throughput de decodificação (43,4 vs 26,9 tok/s) sob idêntico modelo e quantização, validando que a inferência em borda pode quebrar o gargalo de largura de banda de DRAM GDDR5.
2. **Fronteira Física de 4B:** Modelos de 4B operam na margem crítica da VRAM (76,7%). O Gemma-3-4B requer compressão Q4_0 de cache KV para evitar travamento por estouro de memória física.
3. **Frágil Segregação Defensiva:** Embora todos os SLMs exibam FPR = 0,0% em tarefas administrativas benignas, a resiliência a injeções indiretas permanece crítica (ASR $\leq$ 100%). Modelos compactos não devem ter acesso irrestrito a ferramentas de sistema sem uma camada externa de sanitização e autorização explícita de parâmetros.
4. **Penalidade Linguística:** Vocabulários centrados no inglês impõem sobretaxa de até 2,17× no consumo de tokens para a língua portuguesa.

Trabalhos futuros explorarão a aplicação de quantização ternária (1,58 bits) e a instrumentação física de medidores de bancada na linha PCIe para validação térmica e energética direta.

Declaração de Disponibilidade de Dados

Todos os dados brutos de telemetria NVML, traces de benchmark, prompts de avaliação e scripts estatísticos estão integralmente disponíveis publicamente sob licença MIT em:

https://github.com/AndersonTavares0/llm-research-bench

Referências

[1] Williams, S., Waterman, A., Patterson, D. Roofline: An Insightful Visual Performance Model for Multicore Architectures. *Communications of the ACM*, 52(4), 65–76, 2009. https://doi.org/10.1145/1498765.1498785

[2] Leviathan, Y., Kalman, M., Matias, Y. Fast Inference from Transformers via Speculative Decoding. In

Proc. International Conference on Machine Learning (ICML), pp. 19274–19286, 2023.

[3] Röttger, P., et al. XSTest: A Test Suite for Identifying Exaggerated Safety Behaviors in Large Language Models. In *Proc. NAACL*, 2024. arXiv:2308.01263.

[4] Cheng, H., et al. BIPIA: Benchmarking Indirect Prompt Injection Attacks. In *Proc. Findings of the Association for Computational Linguistics (ACL)*, 2024. arXiv:2312.14197.

[5] Debenedetti, E., et al. AgentDojo: A Dynamic Environment to Evaluate Attacks and Defenses on AI Agents. In *Proc. Conference on Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2406.13318.

[6] Wallace, E., et al. The Instruction Hierarchy: Training LLMs to Prioritize Privileged Instructions. arXiv preprint arXiv:2404.13208, 2024.

[7] Souly, A., et al. A StrongREJECT for Empty Jailbreaks. In *Proc. NeurIPS Track on Datasets and Benchmarks*, 2024. arXiv:2402.10260.

[8] Mazeika, M., et al. HarmBench: A Standardized Evaluation Framework for Automated Red Teaming. In *Proc. IEEE Symposium on Security and Privacy (S&P)*, 2024. arXiv:2402.04249.

[9] Chao, P., et al. JailbreakBench: An Open Robustness Benchmark for Large Language Models. In *Proc. NeurIPS Track on Datasets and Benchmarks*, 2023.

[10] Hsieh, C., et al. RULER: What's the Real Context Size of Your Long-Context Language Models? In *Proc. ACL*, 2024. arXiv:2404.06654.

[11] Parrish, A., et al. BBQ: A hand-built bias benchmark for question answering. In *Proc. Findings of the Association for Computational Linguistics (ACL)*, pp. 2086–2105, 2022.

[12] Nadeem, M., Bethke, A., Reddy, S. StereoSet: Measuring stereotypical bias in pretrained language models. In *Proc. ACL-IJCNLP*, pp. 5356–5371, 2021.

[13] Fraser, K. C., et al. Cross-lingual and Cross-cultural Stereotypes in Large Language Models. *Computational Linguistics*, 50(2), 2024.

[14] Dettmers, T., et al. QLoRA: Efficient Finetuning of Quantized LLMs. In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[15] Frantar, E., et al. GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers. In *Proc. International Conference on Learning Representations (ICLR)*, 2023.

[16] Lin, J., et al. AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration. In *Proc. Machine Learning and Systems (MLSys)*, 2024.

[17] Dao, T., et al. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. In *Proc. NeurIPS*, 2022.

[18] Kwon, W., et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *Proc. ACM Symposium on Operating Systems Principles (SOSP)*, 2023.

[19] Miao, X., et al. SpecInfer: Accelerating Generative Large Language Model Serving with Tree-based Speculative Inference and Verification. In *Proc. ASPLOS*, 2024.

[20] Anthropic. Model Context Protocol: Open Standard for Secure AI Agent Tool Integration. Technical Specification, 2024. https://modelcontextprotocol.io