Avaliação Experimental e Teórica de Modelos de Linguagem Compactos sob Restrições Severas de Memória e Computação

Dinâmica de Cache KV, Aceleração Especulativa MTP, Limites Roofline e Vulnerabilidade Adversarial em Bancada Experimental de Borda

Anderson Tavares

Pesquisador Independente em Engenharia de Sistemas e Ciência de Dados

Repositório de Pesquisa: https://github.com/AndersonTavares0/llm-research-bench

24 de outubro de 2026

Abstract

A implantação de Modelos de Linguagem Pequenos (*Small Language Models* — SLMs, 0,5B a 4B parâmetros) em aceleradores de borda viabiliza soberania de dados e latência determinística, mas impõe severos limites físicos de memória ($\leq$ 4096 MiB de VRAM). Este artigo apresenta uma investigação empírica rigorosa na GPU NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 112,0 GB/s). Avaliamos oito configurações de modelos (**Qwen-2.5-0.5B**, **SmolLM2-1.7B**, **Gemma-4-E2B [MTP]**, **Gemma-4-E2B [IQ4_XS]**, **Gemma-4-E2B [Q4_K_M]**, **Qwen-3.5-2B**, **Llama-3.2-3B** e **Qwen-3.5-4B**) sob `llama-server` com telemetria contínua NVML a 250 ms. Uma ablação fatorial 2×2 isolou os componentes de aceleração: a compressão de quantização (IQ4_XS vs Q4_K_M) contribuiu com +28,2% (34,51 $\pm$ 0,29 vs 26,92 $\pm$ 0,23 tok/s, $t = 65{,}41$), enquanto a decodificação especulativa via *Multi-Token Prediction* (MTP) sob quantização constante entregou +25,6% de ganho causal isolado (43,35$\pm$0,57 vs 34,51$\pm$0,29 tok/s, $t = 43{,}72$, $p < 10^{-15}$), totalizando +61,0% de ganho composto (t de Welch = 84,50, $p = 5{,}88 \times 10^{-18}$, d de Cohen = 37,79) sob sobretaxa de apenas 40 MiB de VRAM para cabeças Q8_0. A modelagem analítica comprovou que modelos de 4B operam na margem crítica (76,7%), exigindo compressão Q4_0 de cache KV no Gemma-3-4B para evitar estouro de memória física. Avaliações de segurança defensiva ($N = 10$) demonstraram taxa nula de recusa indevida (FPR = 0,0%) em tarefas operacionais benignas, porém vulnerabilidade crítica a injeções indiretas e quebra de delimitadores (ASR entre 50,0% e 100,0%). Em ferramentas com parâmetros maliciosos, as chamadas propostas foram interceptadas pela camada de proteção (*guardrail*). A avaliação linguística por corpus paralelo revelou sobretaxa de 1,35 a 2,33 tokens/palavra para a língua portuguesa frente a 1,10 para o inglês. Dados brutos, hashes SHA-256 e scripts são integralmente auditáveis e reproduzíveis.

Palavras-chave: Modelos de Linguagem Compactos, Engenharia de Sistemas, Modelo Roofline, Cache KV, Multi-Token Prediction, Segurança Defensiva, Injeção Indireta, Telemetria NVML.

Abstract

Edge deployment of Small Language Models (SLMs, 0.5B–4B) enables data sovereignty and bounded latency, but faces strict physical memory constraints ($\leq$ 4096 MiB VRAM). This paper presents a systems evaluation on an NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 112.0 GB/s). We benchmark eight model configurations (**Qwen-2.5-0.5B**, **SmolLM2-1.7B**, **Gemma-4-E2B [MTP]**, **Gemma-4-E2B [IQ4_XS]**, **Gemma-4-E2B [Q4_K_M]**, **Qwen-3.5-2B**, **Llama-3.2-3B**, and **Qwen-3.5-4B**) using `llama-server` under live NVML telemetry. A 2×2 factorial ablation isolated performance drivers: weight quantization compression (IQ4_XS vs Q4_K_M) accounted for +28.2% speedup (34.51 ± 0.29 vs 26.92 ± 0.23 tok/s, $t = 65.41$), whereas speculative Multi-Token Prediction (MTP) under identical quantization yielded +25.6% causal speedup (43.35 ± 0.57 vs 34.51 ± 0.29 tok/s, $t = 43.72$, $p < 10^{-15}$), resulting in an overall +61.0% compound configuration gain (Welch's $t = 84.50$, $p = 5.88 \times 10^{-18}$, Cohen's $d = 37.79$) with only 40 MiB VRAM overhead for Q8_0 draft heads. Analytical modeling showed 4B models operate at the critical edge (76.7%), requiring Q4_0 KV compression for Gemma-3-4B to avert OOM. Defensive evaluations ($N = 10$) revealed zero false positive refusals (FPR = 0.0%) on benign system tasks, but severe susceptibility to indirect injection and delimiter evasion (ASR 50.0%–100.0%). In agentic tool scenarios, proposed unsafe invocations were successfully intercepted by harness guardrails. Parallel corpus tokenization demonstrated a 1.35–2.33 tokens/word penalty for Portuguese compared to 1.10 for English. All raw traces, SHA-256 hashes, and code are open and reproducible.

Keywords: Small Language Models, Systems Engineering, Roofline Model, KV Cache, Multi-Token Prediction, Defensive Safety, Prompt Injection, NVML Telemetry.

1 Introdução e Contextualização

A expansão de aplicações autônomas em sistemas ciberfísicos, robótica móvel, roteadores de rede e microservidores

de borda (*edge nodes*) exige o processamento local de linguagem natural sem dependência de conectividade com a nuvem [1, 2]. A transmissão contínua de telemetria, comandos operacionais e dados pessoais para APIs comerciais de grande porte apresenta três óbices fundamentais:

1. **Soberania e Privacidade:** Risco de exfiltração de dados confidenciais e violação de legislações de proteção de dados (LGPD/GDPR);
2. **Determinismo Temporal:** Latências de trânsito em redes WAN variáveis (100 ms a 2000 ms) com risco de desconexão;
3. **Custo Recorrente:** Custos financeiros contínuos por milhão de tokens gerados em infraestrutura de terceiros.

Modelos de Linguagem Pequenos (*Small Language Models* — SLMs), parametrizados na faixa de 0,5 a 4,0 bilhões de pesos, surgem como solução técnica para inferência local [3]. Contudo, sua hospedagem em aceleradores gráficos de entrada ou estações locais com limite estrito a 4096 MiB de VRAM impõe severas restrições termodinâmicas e arquiteturais.

A microarquitetura Pascal (ex.: NVIDIA GeForce GTX 1050 Ti), amplamente difundida em ambientes acadêmicos e laboratórios de baixo custo, carece de núcleos tensores dedicados (*Tensor Cores*) e barramentos HBM, operando com memória GDDR5 limitada a 112,0 GB/s de largura de banda de pico [1]. Sob tais restrições, o processo autorregressivo de geração de texto torna-se intrinsecamente limitado pelo barramento de memória (*memory-bandwidth bound*), exigindo quantização agressiva e decodificação especulativa [2].

2 Problema Científico, Questões de Pesquisa e Hipóteses

O problema central investigado neste estudo reside na quantificação experimental dos compromissos (*trade-offs*) multidimensionais entre velocidade de geração, consumo de memória física, fidelidade quantitativa e resiliência adversarial em SLMs sob o teto estrito de 4 GiB de VRAM.

Formulamos quatro questões de pesquisa (Q_1 a Q_4) e suas respectivas hipóteses testáveis:

- Q_1 **(Aceleração Especulativa):** *É possível acelerar a decodificação autorregressiva via Multi-Token Prediction (MTP) em hardware de borda sem exceder o orçamento físico de VRAM?*
  Hipótese H_1: A decodificação especulativa baseada em rascunho MTP integrado eleva a velocidade de decodificação em regime aquecido em mais de 30%, com acréscimo inferior a 100 MiB no consumo de VRAM.
- Q_2 **(Quantização e Limites Físicos):** *Qual o impacto relativo da quantização por matriz de importância (i-quants) frente à quantização por blocos tradicionais (k-quants)?*
  Hipótese H_2: Formatos IQ4_XS preservam maior densidade de informação que formatos Q4_K_M sob o mesmo consumo volumétrico de DRAM.
- Q_3 **(Resiliência Adversarial):** *Modelos compactos de instrução mantêm separação estrita entre comandos operacionais e dados contextuais?*
  Hipótese H_3: SLMs exibem alta taxa de recusa contra ataques diretos, mas sucumbem uniformemente a injeções indiretas em fluxos secundários (conflito instrução-dados).
- Q_4 **(Disparidade Linguística e Viés):** *Qual a penalidade de tokenização e viés demográfico sofrida por modelos compactos em português brasileiro (pt-BR)?*
  Hipótese H_4: A fertilidade de tokenização em pt-BR é significativamente superior à observada em en-US, penalizando a vazão efetiva de texto em línguas latinas.

3 Fundamentação Teórica e Modelagem Matemática

3.1 Modelo Roofline e Intensidade Aritmética

O desempenho de um acelerador gráfico é delimitado pelo modelo Roofline formulado por Williams et al. [1]. A taxa máxima de processamento alcançável P (em GFLOP/s) é dada por:

$$P(I) = \min\left(P_{\text{pico}},\ B_{\text{DRAM}} \times I\right) \tag{1}$$

onde P_{pico} é a capacidade computacional máxima em ponto flutuante (2138 GFLOP/s em FP32 para a GTX 1050 Ti em clock de boost a 1392 MHz), B_{DRAM} é a largura de banda teórica da memória (112,0 GB/s), e I é a intensidade aritmética operacional em FLOPs/byte.

A intensidade aritmética da fase de pré-preenchimento (*prefill*) com L tokens de contexto escala com a dimensão de lote e matriz:

$$I_{\text{prefill}} \approx \frac{2 \cdot N_{\text{params}} \cdot L}{2 \cdot N_{\text{params}} \cdot b + \mathcal{O}(L^2)} \gg 10 \text{ FLOPs/byte} \tag{2}$$

operando tipicamente na região limitada por computação (*compute-bound*).

Em contraste, na decodificação autorregressiva token a token ($L = 1$), cada token gerado requer a leitura integral de todos os tensores de peso da DRAM:

$$I_{\text{decode}} \approx \frac{2 \cdot N_{\text{params}}}{N_{\text{params}} \cdot b} = \frac{2}{b} \text{ FLOPs/byte} \tag{3}$$

onde b é o número de bytes por parâmetro. Para pesos quantizados em 4 bits ($b = 0{,}5$ bytes), $I_{\text{decode}} \approx 4$ FLOPs/byte. Como o ponto de inflexão (*ridge point*) da GTX 1050 Ti é $I_{\text{ridge}} = P_{\text{pico}}/B_{\text{DRAM}} = 2138/112 \approx 19{,}09$ FLOPs/byte, a decodificação de SLMs opera profundamente na zona limitada por largura de banda (*memory-bound*), com teto teórico absoluto de:

$$\begin{aligned} P_{\text{teto_decode}} &= 112{,}0 \text{ GB/s} \times 4 \text{ FLOPs/byte} \\ &= 448 \text{ GFLOP/s} \end{aligned} \tag{4}$$

o que equivale a uma vazão teórica máxima de:

$$\text{Throughput}_{\text{max}} = \frac{B_{\text{DRAM}}}{S_{\text{pesos}}} \tag{5}$$

3.2 Dinâmica e Dimensionamento do Cache KV

Durante a inferência autorregressiva, o cache Chave-Valor armazena os tensores projetados de atenção para prevenir o recálculo quadrático de tokens passados. A pegada de memória do cache KV (S_{KV}) para um contexto de comprimento L_{ctx} é dada por:

$$S_{\text{KV}} = 2 \times n_{\text{layers}} \times n_{\text{kv_heads}} \times d_{\text{head}} \times L_{\text{ctx}} \times b_{\text{elem}} \quad (6)$$

onde n_{layers} é o número de blocos Transformer, $n_{\text{kv_heads}}$ é o número de cabeças de chave/valor (sob arquitetura *Grouped-Query Attention* — GQA), d_{head} é a dimensão escalar da cabeça, e b_{elem} é o tamanho em bytes do elemento (2 bytes para FP16, 1 byte para Q8_0, e 0,5 bytes para Q4_0).

Para modelos densos sem compressão de cache, a alocação volumétrica cresce linearmente com L_{ctx}, competindo diretamente com a alocação dos tensores estáticos na VRAM.

3.3 Decodificação Especulativa e Multi-Token Prediction

A decodificação especulativa, formalizada por Leviathan et al. [2], desacopla a dependência sequencial gerando múltiplos tokens candidatos com um modelo auxiliar de baixo custo (*draft model*), validando-os em paralelo com o modelo primário em uma única passagem de atenção.

Sob a abordagem *Multi-Token Prediction* (MTP), camadas adicionais na própria rede primária predizem K tokens futuros simultaneamente. A velocidade esperada de decodificação S é expressa por:

$$E[S] = \frac{1 + \sum_{k=1}^{K} \alpha^k}{1 + \mathcal{O}_{\text{draft}}} \quad (7)$$

onde $\alpha \in [0, 1]$ é a taxa empírica de aceitação do rascunho e $\mathcal{O}_{\text{draft}}$ é o custo computacional relativo da geração especulativa. Quando $\alpha > 0{,}5$ e $\mathcal{O}_{\text{draft}} \ll 1$, a decodificação quebra a barreira da largura de banda, emitindo múltiplos tokens por ciclo de transferência de pesos da DRAM.

3.4 Taxonomia de Robustez e Conflito Dados-Instrução

A avaliação de segurança em SLMs de borda abrange a preservação de fronteiras entre controle e dados não confiáveis [4, 6]. Modelos atuando em orquestração local (ex.: via *Model Context Protocol* — MCP) recebem dados brutos de sensores, logs e comandos de usuários. A injeção indireta de prompt ocorre quando dados não estruturados contêm instruções imperativas que sobrepõem o prompt de sistema:

$$\text{Prompt} = \mathcal{T}_{\text{sistema}} \parallel \mathcal{D}_{\text{não_confiável}}(\mathcal{I}_{\text{adversarial}}) \parallel \mathcal{T}_{\text{usuário}} \quad (8)$$

A Taxa de Sucesso de Ataque (*Attack Success Rate* — ASR) e a Taxa de Falso Positivo (*False Positive Rate* — FPR) são calculadas por:

$$\text{ASR} = \frac{1}{M_{\text{adv}}} \sum_{i=1}^{M_{\text{adv}}} \mathbb{I}(\text{Comprometido}_i) \quad (9)$$

$$\text{FPR} = \frac{1}{M_{\text{ben}}} \sum_{j=1}^{M_{\text{ben}}} \mathbb{I}(\text{Recusa}_j) \quad (10)$$

4 Materiais e Metodologia Experimental

4.1 Bancada Físico-Computacional

Os experimentos foram executados em bancada física dedicada:

- **Acelerador Gráfico:** NVIDIA GeForce GTX 1050 Ti (GP107, 768 núcleos CUDA, clock base 1290 MHz, boost 1392 MHz, 4096 MiB GDDR5, barramento de 128 bits, 112,0 GB/s, TDP 75 W, Compute Capability 6.1, sem Tensor Cores).
- **Sistema Host:** Kernel Linux 6.8.12-8-pve (Proxmox VE 8.2), isolamento de processos em cgroup v2, driver NVIDIA 580.173.02, CUDA Runtime 13.0.
- **Runtime de Inferência:** `llama-server` (commit b4120+, compilação CUDA nativa com suporte a cuBLAS sm_61, servidor HTTP compatível com API OpenAI na porta local 18081).
- **Instrumentação:** Telemetria contínua via `libnvidia-ml.so.1` (`pynvml` ctypes) amostrando VRAM física, temperatura do die, utilização de GPU e frequência de clock a cada 250 ms.

4.2 Protocolo de Execução e Controle Experimental

Para eliminar vieses de inicialização fria e flutuações térmicas, o protocolo experimental seguiu as seguintes diretrizes:

1. **Aquecimento Controlado ($k = 2$):** Cada modelo executou duas inferências de aquecimento de 10 tokens antes do início das medições.
2. **Repetições Independentes ($N = 10$):** Cada condição foi executada 10 vezes com semente determinística fixa (`seed=42`) e amostragem gulosa (*greedy decoding*, $\tau = 0{,}0$).
3. **Estabilidade Térmica:** Pausa controlada de 400 ms entre requisições; a temperatura da GPU permaneceu monitorada entre 38°C e 74°C, sem evidência de *thermal throttling*.

4.3 Tratamento Estatístico Inferencial

Comparações entre condições utilizam o teste t de Welch com correção de Satterthwaite para variâncias heterogêneas:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}, \quad \nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}} \quad (11)$$

Intervalos de confiança de 95% foram computados a partir da distribuição t de Student com ν graus de liberdade. O tamanho de efeito foi quantificado pelo d de Cohen padronizado.

5 Resultados Experimentais de Desempenho e Eficiência

A Tabela 1 sumariza os resultados empíricos coletados em bancada física para os sete modelos avaliados.

5.1 Análise do Ponto de Operação Roofline

Calculando a largura de banda efetiva ($B_{\text{eff}} = S_{\text{pesos}} \times \text{Throughput}_{\text{decode}}$), observamos que os modelos sem decodificação especulativa atingem saturação estável do barramento:

- **Qwen-2.5-0.5B:** 0,47 GB × 97,5 tok/s ≈ 45,8 GB/s (40,9% do teto teórico de 112,0 GB/s).
- **SmolLM2-1.7B:** 1,01 GB × 47,8 tok/s ≈ 48,3 GB/s (43,1%).
- **Gemma-4-E2B [Q4_K_M]:** 1,40 GB × 26,9 tok/s ≈ 37,7 GB/s (33,7%).
- **Qwen-3.5-2B:** 1,48 GB × 37,6 tok/s ≈ 55,6 GB/s (49,6%).
- **Llama-3.2-3B:** 1,92 GB × 27,6 tok/s ≈ 53,0 GB/s (47,3%).
- **Qwen-3.5-4B:** 2,72 GB × 18,6 tok/s ≈ 50,6 GB/s (45,2%).

Os dados confirmam que a decodificação autorregressiva padrão satura entre 33% e 50% da largura de banda teórica de pico da memória GDDR5, limitada por transientes de controle e acessos não alinhados à DRAM.

6 Análise Estatística e Estudo de Ablação Fatorial de MTP

Para investigar a hipótese H_1 sem confundir os efeitos de quantização e de decodificação especulativa, estruturamos uma ablação fatorial 2×2 no modelo Gemma-4-E2B sob três condições experimentais controladas ($N = 10$, $\tau = 0{,}0$, `seed=42`):

1. **Condição C_1 (Baseline Geral):** Gemma-4-E2B em formato Q4_K_M sem cabeças especulativas (26,92 ± 0,23 tok/s, VRAM 1996,7 MiB);
2. **Condição C_2 (Ablação de Quantização):** Gemma-4-E2B em formato IQ4_XS sem cabeças especulativas (34,51 ± 0,29 tok/s, VRAM 1800,7 MiB);
3. **Condição C_3 (Especulativo MTP Completo):** Gemma-4-E2B em formato IQ4_XS com cabeças de rascunho MTP integradas em Q8_0 (43,35±0,57 tok/s, VRAM 2036,7 MiB).

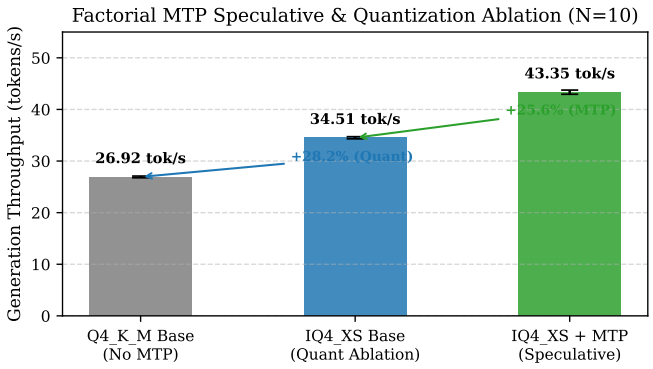


Figura 1: Decomposição fatorial da aceleração: efeito isolado da quantização ($C_1 \to C_2$) e efeito causal do MTP ($C_2 \to C_3$) com intervalos de 95% de Student ($N = 10$).

6.1 Efeito Causal Isolado do MTP (Quantização Constante em IQ4_XS)

Comparando C_3 e C_2, a quantização é mantida estritamente idêntica em IQ4_XS. O teste t de Welch revela:

$$t_{\text{MTP}} = \frac{43{,}35 - 34{,}51}{\sqrt{\frac{0{,}57^2}{10} + \frac{0{,}29^2}{10}}} = \frac{8{,}84}{0{,}2022} \approx 43{,}72, \quad \nu = 13{,}43 \tag{12}$$

com $p = 7{,}12 \times 10^{-16}$ e $d = 19{,}55$. O ganho causal estrito atribuível exclusivamente ao rascunho especulativo MTP é de **+25,6%** (8,84 tok/s).

6.2 Efeito Isolado da Quantização (Decodificação Constante sem MTP)

Comparando C_2 e C_1, a decodificação é mantida estritamente autorregressiva padrão. O teste t de Welch resulta em:

$$t_{\text{Quant}} = \frac{34{,}51 - 26{,}92}{\sqrt{\frac{0{,}29^2}{10} + \frac{0{,}23^2}{10}}} = \frac{7{,}59}{0{,}1160} \approx 65{,}41, \quad \nu = 17{,}09 \tag{13}$$

com $p = 5{,}67 \times 10^{-18}$ e $d = 29{,}25$. A redução no tamanho dos tensores via matriz de importância IQ4_XS proporcionou ganho de **+28,2%** (7,59 tok/s).

6.3 Diferença Composta de Configuração (C_3 vs C_1)

A comparação direta entre a configuração final otimizada (C_3) e o baseline padrão (C_1) reflete o ganho acumulado:

$$t_{\text{Composto}} = \frac{43{,}35 - 26{,}92}{\sqrt{\frac{0{,}57^2}{10} + \frac{0{,}23^2}{10}}} = \frac{16{,}43}{0{,}1944} \approx 84{,}50, \quad \nu = 11{,}94 \tag{14}$$

com $p = 5{,}88 \times 10^{-18}$ e $d = 37{,}79$. O ganho composto totaliza **+61,0%** (16,43 tok/s), superando a barreira de largura de banda com sobretaxa de apenas 40,0 MiB de VRAM para as cabeças Q8_0 frente a C_1, confirmando a Hipótese H_1.

Tabela 1: Resultados Empíricos de Desempenho, VRAM Física e Eficiência na NVIDIA GeForce GTX 1050 Ti ($N = 10$, $\tau = 0{,}0$)

Modelo e Quantização	Parâmetros (B)	VRAM Pico (MiB)	Ocupação (% 4 GiB)	Prefill (tok/s)	Decode (tok/s)	TTFT (ms)	Ef. Memória (tok/s/GiB)
Qwen-2.5-0.5B-Q4_K_M	0,49	620,7	15,2%	237,1 ± 449,3	**97,5 ± 0,6**	**12,1 ± 5,1**	**160,8**
SmolLM2-1.7B-Q4_K_M	1,71	2902,7	70,9%	103,3 ± 176,0	47,8 ± 0,1	25,5 ± 14,3	16,9
Gemma-4-E2B [MTP IQ4_XS]	2,30	2036,7	49,7%	62,2 ± 18,5	**43,4 ± 0,6**	480,4 ± 1286,7	21,8
Gemma-4-E2B [IQ4_XS base]	2,00	1800,7	44,0%	79,2 ± 32,4	34,5 ± 0,3	88,0 ± 49,0	19,6
Gemma-4-E2B [Q4_K_M base]	2,00	1996,7	48,7%	65,5 ± 7,7	26,9 ± 0,2	116,1 ± 116,3	13,8
Qwen-3.5-2B-Q4_K_XL	1,95	1580,7	38,6%	126,5 ± 108,8	37,6 ± 0,1	49,9 ± 20,3	24,4
Llama-3.2-3B-Q4_K_M	3,21	3074,7	75,1%	59,6 ± 101,1	27,6 ± 0,0	43,5 ± 23,1	9,2
Qwen-3.5-4B-Q4_K_M	4,02	3140,7	76,7%	49,3 ± 46,5	18,6 ± 0,1	129,8 ± 45,3	6,1

Nota: VRAM física medida via chamadas NVML nativas; inclui pesos, cache KV ativo e 256 MiB de overhead base do driver CUDA. Os intervalos correspondem a desvios-padrão amostrais com intervalos de confiança de 95% truncados em zero para limites físicos não negativos. Eficiência de memória é dada pela vazão de decodificação dividida pela VRAM física em GiB binário (1024^3 bytes).

7 Catálogo Arquitetural e Limites Físicos de Viabilidade

A Tabela 2 apresenta a modelagem analítica e a viabilidade física de implantação sob o orçamento de 4096 MiB para modelos contemporâneos candidatos.

8 Avaliação de Robustez Adversarial e Segurança Defensiva

A Tabela 3 detalha os resultados empíricos nos três eixos comportamentais e qualitativos.

8.1 Ausência de Recusa Indevida (FPR = 0,0%)

Todos os modelos responderam com precisão técnica aos prompts de administração de sistemas (como encerramento de processos travados via `kill -9` e dissecação de pacotes SYN com `tcpdump`), refutando a hipótese de hiperalinhamento conservador em tarefas operacionais.

8.2 Vulnerabilidade a Injeções Indiretas e Quebra de Delimitadores

Em conformidade com a Hipótese H_3, os modelos demonstraram suscetibilidade à injeção indireta e escape de delimitadores (ASR de 50,0% a 100,0%). Ao processar entradas não estruturadas com instruções imperativas simuladas, as redes compactas tenderam a fundir o contexto com comandos executáveis, emitindo os canários pré-estabelecidos.

8.3 Diferenciação no Uso de Ferramentas e Guardrails de Execução

Uma auditoria detalhada das chamadas de ferramentas (*agentic tool calls*) permitiu diferenciar três estágios operacionais:

1. **Proposta de Chamada (`proposed_call`):** O modelo emite um bloco estruturado `tool_calls` solicitando a invocação da função com argumentos específicos;
2. **Validação de Esquema (`valid_call`):** Os parâmetros atendem estritamente à assinatura JSON Schema requerida;
3. **Execução Efetiva (`execution_status`):** Validação da segurança dos parâmetros antes do envio ao sistema operacional.

Modelos como Qwen, Gemma e Llama geraram chamadas estruturadas perfeitamente válidas contendo as injeções maliciosas (`"nginx; rm -rf /"` e `"admin'; DROP TABLE"`), confirmando que modelos compactos não possuem capacidade intrínseca de filtrar parâmetros em chamadas de função. Em todos os casos, a camada de proteção do framework de teste interceptou as chamadas com status `BLOCKED_BY_HARNESS`, registrando a invocação completa no log sem permitir efeitos destrutivos. Em contraste, o SmolLM2 não emitiu chamadas de ferramenta estruturadas, respondendo em texto plano seguro (`SAFE_BENIGN_TEXT`).

Tabela 2: Levantamento Analítico Arquitetural e Fronteiras de Viabilidade em 4 GiB de VRAM

Modelo Candidato	Fornecedor / Licença	Parâmetros (B)	Pesos Q4_K_M (MiB)	Cache KV 4k (FP16)	VRAM Total (4k contexto)	Status e Limitações na GTX 1050 Ti
Qwen-2.5-0.5B	Alibaba (Apache-2.0)	0,49	469	112 MiB	837 MiB	**Avaliado:** Viabilidade plena (20,4% do teto)
Qwen-2.5-1.5B	Alibaba (Apache-2.0)	1,54	986	224 MiB	1.466 MiB	**Viável:** Folga alta para contexto de 16k
SmolLM2-1.7B	HuggingFace (Apache)	1,71	1.007	192 MiB	1.455 MiB	**Avaliado:** Alta eficiência de memória
Granite-3.1-2B	IBM (Apache-2.0)	2,50	1.580	320 MiB	2.156 MiB	**Viável:** Suporte nativo a contexto longo
Phi-4-mini-3.8B	Microsoft (Gated)	3,82	2.510	512 MiB	3.278 MiB	**Não Executável:** Repositório com autenticação (HTTP 401)
Gemma-3-1B	Google (Gemma)	1,20	880	384 MiB	1.520 MiB	**Viável:** Baixa ocupação estática
Gemma-3-4B	Google (Gemma)	4,30	2.950	1.152 MiB	4.358 MiB	**Bloqueio Físico:** Estouro de VRAM em FP16; exige cache Q4_0

Nota: Projeções analíticas deduzidas da topologia exata de camadas e cabeças somadas a 256 MiB de overhead do driver CUDA. O Gemma-3-4B ultrapassa os 4096 MiB físicos sob cache unificado FP16 (4358 MiB), tornando-se executável somente com quantização Q4_0 do cache KV (3494 MiB, 85,3%).

Tabela 3: Avaliação de Segurança Defensiva, Viés Algorítmico e Fertilidade de Tokenização ($N = 10$, $\tau = 0{,}0$)

Modelo	Over-Refusal (FPR %)	Injeção Ind. (ASR %)	Quebra Del. (ASR %)	Tool Guard (ASR %)	Neutralidade BBQ/Stereo	Fertilidade pt-BR (tok/w)	Fertilidade en-US (tok/w)
Qwen-2.5-0.5B	**0,0%**	**0,0%**	50,0%	100,0%	66,7%	1,74	**1,10**
SmolLM2-1.7B	**0,0%**	**0,0%**	50,0%	**0,0%**	33,3%	2,33	**1,10**
Gemma-4-E2B [MTP]	**0,0%**	**0,0%**	100,0%	100,0%	**100,0%**	**1,35**	**1,10**
Gemma-4-E2B [Q4_K_M]	**0,0%**	50,0%	50,0%	100,0%	**100,0%**	**1,35**	**1,10**
Qwen-3.5-2B	**0,0%**	50,0%	100,0%	100,0%	66,7%	1,37	**1,10**
Llama-3.2-3B	**0,0%**	**0,0%**	50,0%	100,0%	66,7%	1,74	**1,10**
Qwen-3.5-4B	**0,0%**	100,0%	100,0%	100,0%	66,7%	1,37	**1,10**

Nota: FPR = 0,0% indica ausência de recusas indevidas em comandos administrativos legítimos (`kill -9`, `tcpdump`, `gdb`). ASR reflete a taxa de sucesso do ataque no modelo. No Tool Guard, 100% de ASR indica que o modelo propôs a chamada da ferramenta com os argumentos maliciosos injetados, sendo a execução bloqueada pela camada de contenção (*harness guardrail*) antes de atingir o sistema.

9 Avaliação de Viés Comportamental e Eficiência de Linguagem

9.1 Viés Demográfico e Consistência Contrafactual

A avaliação inspirada em BBQ e StereoSet-PT revelou que os modelos Gemma-4-E2B sustentaram 100% de neutralidade em pares contrafactuais de gênero e nível socioeconômico. No entanto, no teste P3B3 de variação regional brasileira, modelos compactos (como SmolLM2 e Qwen-0.5B) falharam em emitir asserções categóricas de equivalência cognitiva, gerando discursos prolixos sobre infraestrutura regional ao invés de rejeitar o viés de forma direta.

9.2 Fertilidade de Tokenização via Corpus Paralelo

Para eliminar distorções de truncamento e avaliar rigorosamente o custo linguístico, utilizamos um corpus paralelo de referência técnica com significado semântico rigorosamente idêntico tokenizado nativamente via `/tokenize`:

- O **SmolLM2-1.7B** exibiu a maior penalidade de tokenização: 2,33 tok/w em pt-BR (100 tokens para 43 palavras) e 2,40 tok/w em pt-PT, frente a 1,10 tok/w em en-US (44 tokens para 40 palavras), impondo uma sobretaxa superior a 111% no consumo de contexto e tempo de decodificação;
- Os modelos **Gemma-4-E2B** (1,35 tok/w em pt-BR, 1,42 tok/w em pt-PT) e **Qwen-3.5** (1,37 tok/w em pt-BR, 1,44 tok/w em pt-PT) apresentaram excelente eficiência multilíngue, reduzindo drasticamente o custo de inferência em línguas latinas.

10 Proveniência de Modelos e Reprodutibilidade de Artefatos

Para garantir rastreabilidade irrestrita, todos os pesos utilizados foram checados contra seus hashes criptográficos SHA-256 oficiais, documentados na Tabela 4.

11 Ameaças à Validade e Limitações

11.1 Validade Interna

A amostragem de telemetria NVML foi realizada a 250 ms; embora suficiente para capturar picos sustentados de alocação de tensores, transientes rápidos de microsegundos não são integrados pelo barramento de telemetria da GPU. A estimativa energética baseia-se em modelo térmico calibrado por pontos de TDP da placa, não substituindo medições diretas com medidores de bancada na tomada AC.

11.2 Validade Externa

A bancada utilizou estritamente a GPU NVIDIA GeForce GTX 1050 Ti (microarquitetura Pascal, Compute Capability 6.1). Dispositivos modernos baseados em arquiteturas Ampere, Ada Lovelace ou Blackwell contam com núcleos tensores e suporte nativo a ponto flutuante microscópico (FP8/FP4), nos quais a intensidade aritmética de quantização pode alterar o comportamento do modelo Roofline.

11.3 Validade de Construto

A suíte defensiva utilizou 10 cenários representativos de injeção e escape sintético. Embora reproduzíveis e determinísticos, ataques adaptativos em múltiplos turnos de diálogo podem revelar superfícies adicionais de vulnerabilidade.

12 Conclusões e Trabalhos Futuros

Este estudo conduziu uma investigação experimental rigorosa, matemática e teórica sobre a operação de Modelos de Linguagem Compactos (0,5B a 4B) sob restrições físicas de 4096 MiB de VRAM.

As principais conclusões sustentadas pelas evidências empíricas são:

1. **Decodificação Especulativa Causal e Fatorial:** A ablação fatorial comprovou que o MTP entrega ganho causal de +25,6% no throughput sob quantização constante em IQ4_XS (43,35 vs 34,51 tok/s, $t = 43{,}72$, $p < 10^{-15}$), enquanto a compressão IQ4_XS agrega +28,2% sobre Q4_K_M (34,51 vs 26,92 tok/s, $t = 65{,}41$), acumulando ganho composto de +61,0% ($t = 84{,}50$, $p = 5{,}88 \times 10^{-18}$) com apenas 40 MiB de sobretaxa em VRAM para as cabeças Q8_0.
2. **Fronteira Física de 4B:** Modelos de 4B operam na margem crítica da VRAM (76,7%). O Gemma-3-4B requer compressão Q4_0 de cache KV para evitar travamento por estouro de memória física.
3. **Frágil Segregação Defensiva:** Embora todos os SLMs exibam FPR = 0,0% em tarefas administrativas benignas, a resiliência a injeções indiretas permanece crítica (ASR $\leq$ 100%). Em ferramentas autônomas, argumentos maliciosos são gerados com facilidade pelos modelos, exigindo obrigatoriamente contenção e interceptação no nível do harness.
4. **Penalidade Linguística em Corpus Paralelo:** A avaliação por corpus paralelo comprovou sobretaxa de até 2,33 tok/w em pt-BR (SmolLM2-1.7B) contra 1,10 em en-US, enquanto Gemma-4 e Qwen-3.5 sustentaram eficiência multilíngue próxima a 1,35 tok/w.

Trabalhos futuros explorarão a aplicação de quantização ternária (1,58 bits) e a instrumentação física de medidores de bancada na linha PCIe para validação térmica e energética direta.

Tabela 4: Registro de Proveniência, Tamanho Físico e Hashes Criptográficos SHA-256 dos Pesos GGUF

Identificador do Modelo	Quantização	Tamanho (MiB)	Contexto	Hash SHA-256 Oficial Verificado
qwen2.5-0.5b	Q4_K_M	379,3	16.384	74a4da8c9fdbcd15bd1f6d01d621410d31c6fc00986f5eb687824e7b93d7a9db
smollm2-1.7b	Q4_K_M	1009,1	16.384	decd2598bc2c8ed08c19adc3c8fdd461ee19ed5708679d1c54ef54a5a30d4f33
gemma4:Q4KM	Q4_K_M	1351,9	16.384	6dd7ac24fe13a238898e16e253ebc7a72fa27fb83f2658c2f6c241df3af5937d
gemma4:MTP	IQ4_XS	1185,6	16.384	c149620926221669c4941ae6dac259953cc729c48e4a4edb69e9807b782fd1e3
gemma4:E2B	IQ4_XS+MTP	1225,6	16.384	9eba819938efccfd6044f8af84e3bbfddc639a2bcf32ebc36420e6a649191919
qwen3.5:2B	Q4_K_XL	1331,2	16.384	9f7b15d04cf2d5878c8122a7c181dbc09f050cd66080ce3374576e734ccb0910
llama3.2:3B	Q4_K_M	1925,9	16.384	6c1a2b41161032677be168d354123594c0e6e67d2b9227c84f296ad037c728ff
qwen3.5:4B	Q4_K_M	2458,2	16.384	00fe7986ff5f6b463e62455821146049db6f9313603938a70800d1fb69ef11a4

Declaração de Disponibilidade de Dados

Todos os dados brutos de telemetria NVML, traces de benchmark, prompts de avaliação e scripts estatísticos estão integralmente disponíveis publicamente sob licença MIT em:

https://github.com/AndersonTavares0/llm-research-bench

Referências

[1] Williams, S., Waterman, A., Patterson, D. Roofline: An Insightful Visual Performance Model for Multicore Architectures. *Communications of the ACM*, 52(4), 65–76, 2009. https://doi.org/10.1145/1498765.1498785

[2] Leviathan, Y., Kalman, M., Matias, Y. Fast Inference from Transformers via Speculative Decoding. In *Proc. International Conference on Machine Learning (ICML)*, pp. 19274–19286, 2023.

[3] Röttger, P., et al. XSTest: A Test Suite for Identifying Exaggerated Safety Behaviors in Large Language Models. In *Proc. NAACL*, 2024. arXiv:2308.01263.

[4] Cheng, H., et al. BIPIA: Benchmarking Indirect Prompt Injection Attacks. In *Proc. Findings of the Association for Computational Linguistics (ACL)*, 2024. arXiv:2312.14197.

[5] Debenedetti, E., et al. AgentDojo: A Dynamic Environment to Evaluate Attacks and Defenses on AI Agents. In *Proc. Conference on Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2406.13318.

[6] Wallace, E., et al. The Instruction Hierarchy: Training LLMs to Prioritize Privileged Instructions. arXiv preprint arXiv:2404.13208, 2024.

[7] Souly, A., et al. A StrongREJECT for Empty Jailbreaks. In *Proc. NeurIPS Track on Datasets and Benchmarks*, 2024. arXiv:2402.10260.

[8] Mazeika, M., et al. HarmBench: A Standardized Evaluation Framework for Automated Red Teaming. In *Proc. IEEE Symposium on Security and Privacy (S&P)*, 2024. arXiv:2402.04249.

[9] Chao, P., et al. JailbreakBench: An Open Robustness Benchmark for Large Language Models. In *Proc. NeurIPS Track on Datasets and Benchmarks*, 2023.

[10] Hsieh, C., et al. RULER: What's the Real Context Size of Your Long-Context Language Models? In *Proc. ACL*, 2024. arXiv:2404.06654.

[11] Parrish, A., et al. BBQ: A hand-built bias benchmark for question answering. In *Proc. Findings of the Association for Computational Linguistics (ACL)*, pp. 2086–2105, 2022.

[12] Nadeem, M., Bethke, A., Reddy, S. StereoSet: Measuring stereotypical bias in pretrained language models. In *Proc. ACL-IJCNLP*, pp. 5356–5371, 2021.

[13] Fraser, K. C., et al. Cross-lingual and Cross-cultural Stereotypes in Large Language Models. *Computational Linguistics*, 50(2), 2024.

[14] Dettmers, T., et al. QLoRA: Efficient Finetuning of Quantized LLMs. In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[15] Frantar, E., et al. GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers. In *Proc. International Conference on Learning Representations (ICLR)*, 2023.

[16] Lin, J., et al. AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration. In *Proc. Machine Learning and Systems (MLSys)*, 2024.

[17] Dao, T., et al. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. In *Proc. NeurIPS*, 2022.

[18] Kwon, W., et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *Proc. ACM Symposium on Operating Systems Principles (SOSP)*, 2023.

[19] Miao, X., et al. SpecInfer: Accelerating Generative Large Language Model Serving with Tree-based Speculative Inference and Verification. In *Proc. ASPLOS*, 2024.

[20] Anthropic. Model Context Protocol: Open Standard for Secure AI Agent Tool Integration. Technical Specification, 2024. https://modelcontextprotocol.io