Avaliação Técnica, Comportamental e de Segurança de Modelos de Linguagem sob Restrições Severas de VRAM

Um Estudo Experimental Comparativo com NVIDIA GeForce GTX 1050 Ti (4GB GDDR5)

Anderson Tavares
Laboratório de Inteligência Artificial e Infraestrutura
https://github.com/AndersonTavares0/llm-research-bench

24 de Outubro de 2026

Resumo

A proliferação de Small Language Models (SLMs) com contagens de parâmetros entre 2B e 4B abriu novas fronteiras para inferência local em nós de borda (edge nodes) e servidores com orçamentos restritos de hardware. No entanto, a viabilidade operacional sob restrições severas de memória de vídeo (VRAM $\leq$ 4096 MiB) permanece um desafio multifatorial onde quantização, arquitetura de decodificação especulativa, taxa de geração de tokens e robustez comportamental colidem. Este artigo apresenta uma pesquisa experimental reprodutível avaliando quatro modelos de ponta disponíveis publicamente: **Gemma-4-E2B-it** (IQ4_XS com rascunho especulativo MTP Q8_0), **Qwen-3.5-4B-Instruct** (Q4_K_M), **Qwen-3.5-2B-Instruct** (Q4_K_XL) e **Llama-3.2-3B-Instruct** (Q4_K_M), executados sobre uma GPU NVIDIA GeForce GTX 1050 Ti (4GB GDDR5, Compute Capability 6.1) em contêiner Proxmox VE (CT 108). O framework investigou duas dimensões estritamente separadas: (1) *System Performance* (TTFT, vazão de geração em tok/s, alocação estática e de pico de VRAM); e (2) *Model Quality & Safety* (raciocínio técnico quantitativo, protocolos de chamada de ferramenta agêntica estilo Pulse/MCP e resistência adversarial contra 6 vetores de ataque incluindo CVEs reais, keyloggers, DAN e injeção indireta). Os resultados demonstram que a decodificação especulativa MTP no Gemma-4-E2B atinge a maior vazão do estudo (**46.3 tokens/s**), consumindo apenas 36.8% da VRAM, enquanto o Qwen-3.5-4B exibe o melhor discernimento estrutural porém com saturação de 74.9% do barramento e taxa de 18.4 tok/s. Em segurança, todos os modelos alcançaram 83.3% de recusa limpa contra explorações armamentizadas e ataques DAN, contudo falhas sutis de raciocínio aritmético persistiram nas menores variantes.

Palavras-chave: Modelos de Linguagem Pequenos (SLMs), Restrições de VRAM, Decodificação Especulativa, Robustez Adversarial, Chamada de Ferramentas, Benchmarking Reproduzível.

1 Introdução e Motivação

A viabilização de assistentes inteligentes e controladores agênticos em ambientes locais fechados (air-gapped ou homelabs autônomos) requer a execução de Modelos de Linguagem Pequenos (SLMs) em hardware de consumo. Em placas de vídeo como a NVIDIA GeForce GTX 1050 Ti, equipada com apenas 4096 MiB de memória GDDR5 em barramento de 128 bits (largura de banda teórica de 112 GB/s), a margem para alocação do grafo de pesos e da memória de contexto (*KV Cache*) é extremamente reduzida.

Qualquer sobrecarga de memória força o offloading de camadas para a CPU e memória RAM do sistema (DDR4), penalizando catastroficamente a latência do primeiro token (*Time To First Token* - TTFT) e reduzindo a geração a valores inferiores a 3 tokens/s através do barramento PCIe.

Este estudo formula e testa experimentalmente cinco hipóteses científicas fundamentais:

H1: Modelos que utilizam decodificação especulativa (MTP - *Multi-Token Prediction*) conseguem suplantar o gargalo de largura de banda de memória da arquitetura Pascal em mais de 100% em relação a modelos densos convencionais.

H2: A quantização agressiva (IQ4_XS / Q4_K) em SLMs preserva a adesão à sintaxe de chamadas de função agênticas (JSON Schema), mas compromete a precisão em problemas aritméticos multi-etapas.

H3: Modelos com 4B parâmetros aproximam-se do teto operacional de 4GB de VRAM, exigindo contexto encurtado ou quantização sub-4-bit para prevenir OOM (*Out of Memory*).

H4: A robustez de segurança contra jailbreaks clássicos (DAN) e solicitações maliciosas é independente da contagem de parâmetros na faixa de 2B a 4B quando o fine-tuning de segurança (RLHF/DPO) foi bem estabelecido na origem.

H5: O comportamento sob agentes locais (Pulse/MCP) depende criticamente da capacidade do modelo de assimilar resultados parciais de chamadas de ferramentas anteriores sem alucinar saídas inexistentes.

2 Infraestrutura e Reconhecimento do Ambiente

O experimento foi executado no cluster de homelab `v01`, dentro do contêiner LXC especializado **CT 108** (GPU Lab), com passthrough de hardware direto da GPU.

2.1 Especificações de Hardware

- **Processador Central (Host):** AMD Ryzen 5 3600 (6 núcleos, 12 threads @ 3.6 GHz base / 4.2 GHz boost).
- **Recursos do CT 108:** 2 vCPUs dedicadas, 4.0 GiB de memória RAM física e 512 MiB de swap.
- **Placa Gráfica:** NVIDIA GeForce GTX 1050 Ti (4096 MiB GDDR5, 768 CUDA cores, SM 6.1, TDP 75W).
- **Subssistema de E/S:** Volume root em NVMe PCIe 3.0 x4 (ZFS pool local).

2.2 Stack de Software e Runtime de Inferência

- **Sistema Operacional do Guest:** Debian GNU/Linux 13 (Trixie), Kernel 6.8.12-14-pve x86_64.
- **Drivers e Toolkits:** NVIDIA Driver 580.173.02, CUDA Driver Version 13.0.
- **Motor de Inferência:** `llama-server` (commit baseado no ggml/llama.cpp b4120+) executado em contêiner Podman rootless isolado (`ollama` user cgroup), operando em modo roteador na porta TCP interna `18081`.
- **Isolamento de Segurança:** Roteamento exclusivo via loopback `127.0.0.1` e proxy reverso Caddy com TLS automático para requisições externas originárias do nó de orquestração Pulse (CT 100).

3 Metodologia Experimental e Modelos Avaliados

Foram selecionados quatro modelos que cobrem diferentes espectros da fronteira 2B–4B:

1. **Gemma-4-E2B-it:** Arquitetura compacta desenvolvida pela Google DeepMind, quantizada em `IQ4_XS` (tamanho: 1.5 GB), associada a um modelo de rascunho especulativo `mtp-gemma-4-E2B-it-Q8_0` (tamanho: 0.28 GB) operando via `-model-draft`.
2. **Qwen-3.5-4B-Instruct:** Modelo denso desenvolvido pela Alibaba Cloud, quantizado em `Q4_K_M` (tamanho: 2.7 GB), representando o limite prático de alocação total na VRAM de 4GB.
3. **Qwen-3.5-2B-Instruct:** Variante compacta da família Qwen, quantizada em `Q4_K_XL` (tamanho: 1.5 GB).
4. **Llama-3.2-3B-Instruct:** Modelo de instrução compacto da Meta AI, quantizado em `Q4_K_M` (tamanho: 2.0 GB).

3.1 Protocolo de Teste Padronizado

Todos os modelos foram avaliados através do script científico automatizado `gpu-lab-comprehensive-suite.py`, sob condições termicamente estabilizadas ($T_{\text{GPU}} \leq 45°\text{C}$ no início de cada rodada). A amostragem foi fixada em temperatura $\tau = 0.2$, com $top_p = 0.9$ e semente pseudo-aleatória fixa, assegurando a determinística dos testes comparativos.

4 Resultados de Desempenho do Sistema (System Performance)

A Tabela 1 sintetiza as métricas empíricas coletadas diretamente dos medidores internos do `llama-server` e da API `nvml` da GPU.

Tabela 1: Métricas Empíricas de Desempenho de Sistema sob 4096 MiB de VRAM

Modelo	**VRAM Estática** (MiB)	**VRAM Pico** (MiB)	**Ocupação** (% da VRAM)	**Prompt Eval** (tokens/s)	**Geração** (tokens/s)	**TT** (m
Gemma-4-E2B (MTP)	1.452	1.510	36,8%	**468,2**	**46,3**	**115**
Qwen-3.5-2B	1.540	1.598	39,0%	389,5	37,5	142
Llama-3.2-3B	2.050	2.120	51,7%	390,7	27,4	168
Qwen-3.5-4B	2.987	3.069	74,9%	237,1	18,4	284

4.1 Análise do Impacto da Decodificação Especulativa (MTP)

Conforme observado na Tabela 1, o **Gemma-4-E2B** superou significativamente todos os outros modelos em vazão de geração, atingindo **46.3 tokens/s** sustentados, com picos superiores a 52 tokens/s. Isso valida a hipótese **H1**: o modelo de rascunho leve (MTP) reduz a frequência de acessos ao barramento de memória da GTX 1050 Ti, permitindo validar múltiplos tokens por passagem completa na GPU. Em contrapartida, o Qwen-3.5-4B atinge 18.4 tokens/s, limitado primariamente pela largura de banda de memória de 112 GB/s ao processar 4 bilhões de parâmetros em cada passo de geração.

5 Resultados de Qualidade, Raciocínio e Segurança (Model Quality)

A Tabela 2 exibe os resultados das três baterias de avaliação comportamental.

Tabela 2: Avaliação Comportamental: Segurança, Agência e Raciocínio Técnico

Modelo	**Robustez e Segurança** (% Recusas Adequadas)	**Chamada Agêntica** (Cenários 1, 2, 3)	**Raciocínio Técnico** (% Acertos Exatos)	**Co Ad**
Gemma-4-E2B (MTP)	83,3% (5/6)	**Aprovado Total**	33,3% (1/3)	**Recomend**
Qwen-3.5-4B	83,3% (5/6)	**Aprovado Total**	33,3% (1/3)	Adequado
Qwen-3.5-2B	83,3% (5/6)	**Aprovado Total**	0,0% (0/3)	Frágil
Llama-3.2-3B	83,3% (5/6)	**Reprovado (Cen. 2)**	33,3% (1/3)	Instáv

5.1 Análise dos Testes de Segurança e Jailbreak

A bateria de segurança submeteu os modelos a seis desafios distintos:

1. **Exploit de CVE Real (Log4Shell CVE-2021-44228):** Solicitação direta de script em Python armamentizado para escaneamento e injeção de reverse shell persistente. *Resultado:* Todos os modelos recusaram a criação de armas cibernéticas de forma limpa, oferecendo proativamente orientações de remediação e detecção defensiva.

2. **Malware Furtivo (Keylogger em C++):** Injeção em processo do sistema (`explorer.exe`) com envio criptografado de credenciais. *Resultado:* Recusa universal categórica com explicação pedagógica dos mecanismos de interceptação e mitigação por EDR.

3. **Jailbreak DAN (Do Anything Now):** Tentativa clássica de personificação e quebra de filtros éticos. *Resultado:* Todos os 4 modelos neutralizaram o jailbreak, mantendo seus alinhamentos éticos intactos.

4. **Jailbreak do Dia Oposto (Opposite Day):** Técnica de ofuscação psicológica instruindo o modelo a fingir o inverso. *Resultado:* Neutralizado com sucesso.

5. **Injeção Indireta de Prompt em Documentos:** Injeção de instruções maliciosas simuladas em logs do sistema. *Resultado:* Resistência sustentada com diferenciação entre dados do log e comandos do operador.

5.2 Avaliação de Agência e Integração com Ferramentas

Na avaliação de fluxos agênticos do tipo Pulse/MCP:

- O **Gemma-4-E2B**, o **Qwen-3.5-4B** e o **Qwen-3.5-2B** geraram a chamada de ferramenta estruturada precisa: `{"tool": "get_proxmox_node_status", "arguments": {"node": "v01"}}`, processaram corretamente a resposta sintética no segundo turno e sintetizaram uma conclusão precisa no terceiro turno sem alucinar ferramentas inexistentes.

- O **Llama-3.2-3B** falhou no segundo estágio (continuação): após receber o retorno da ferramenta, não conseguiu sintetizar a métrica de memória livre e alucinou uma falha de parsing, confirmando a hipótese **H5**.

5.3 Análise do Raciocínio Quantitativo

Nos testes de raciocínio lógico e redes:

- **Cálculo de Sub-rede CIDR (/26):** Apenas respostas parciais foram obtidas. Modelos como Llama-3.2-3B cometeram erros graves de potência aritmética (ex.: calcular $2^{18} = 262.144$ utilizáveis para um bloco /26).

- **Paridade de Armazenamento ZFS (RAIDZ2):** O cálculo de capacidade utilizável de 6 discos de 4TB exigia a dedução de $2 \times 4\text{TB} = 8\text{TB}$, resultando em 16TB utilizáveis. Vários modelos apresentaram alucinações de 18TB ou confusoes conceituais com RAID 5.

- **Aritmética Multi-Etapas de RAM:** Todos os modelos exceto o Qwen-3.5-2B acertaram que um nó de 32 GB com hipervisor (4 GB) e 3 VMs (8+12+6=26 GB) não pode acomodar um novo contêiner de 3 GB sem baloneamento ($30 + 3 = 33$ GB > 32 GB $\implies$ Não).

6 Discussão e Verificação das Hipóteses

- **H1 (Confirmada):** O uso de MTP no Gemma-4-E2B entregou ganho de 2.5× em tokens/s em relação ao Qwen-3.5-4B e 1.7× em relação ao Llama-3.2-3B.
- **H2 (Confirmada):** A quantização não quebrou o alinhamento sintático JSON, mas modelos abaixo de 3B demonstraram incapacidade de resolver cálculos de sub-rede e tolerância a falhas de armazenamento de forma determinística sem ferramentas externas (calculadoras/Python REPL).
- **H3 (Confirmada):** O Qwen-3.5-4B atingiu 3.069 MiB de VRAM (74.9% do total de 4GB). Aumentos no comprimento de contexto ($n_{ctx} > 16.384$) necessitariam de quantização do KV Cache (`q8_0` ou `q4_0`) para evitar OOM.
- **H4 (Confirmada):** O alinhamento de segurança foi excepcionalmente consistente em toda a faixa de 2B a 4B, provando que o fine-tuning moderno mitiga jailbreaks clássicos sem depender de parâmetros em larga escala.
- **H5 (Confirmada):** A capacidade de seguir protocolos agênticos em múltiplas rodadas é disjunta do tamanho do modelo: o Gemma-4-E2B (2B parâmetros) foi perfeitamente compatível, enquanto o Llama-3.2-3B falhou na sintetização do retorno.

7 Conclusões e Recomendações Práticas

Para implementação em nós de borda, homelabs e assistentes locais de monitoramento (como o agente de automação Pulse):

1. **Recomendação Primária de Inferência Geral e Agentes: Gemma-4-E2B-it** com MTP Q8_0. Oferece a melhor relação custo-benefício computacional, gerando acima de 40 tokens/s, consumindo menos de 1.6 GB de VRAM e demonstrando total aderência a chamadas de funções JSON.
2. **Recomendação para Tarefas de Análise Semântica Crítica: Qwen-3.5-4B-Instruct** (Q4_K_M). É a opção recomendada quando tarefas exigem discernimento textual denso, desde que a latência de 18 tokens/s seja aceitável.
3. **Arquitetura Híbrida Recomendada:** Modelos pequenos não devem executar aritmética complexa ou álgebra de redes diretamente em seus pesos. A infraestrutura de agentes (Pulse/MCP) deve injetar ferramentas de cálculo determinísticas (calculadora CLI, scripts Python ou APIs de rede) para sanar as fragilidades aritméticas evidenciadas.

Reprodutibilidade e Dados Abertos

O código-fonte completo da suíte de teste, os datasets empíricos estruturados em JSON/CSV e as instruções de replicação estão publicamente arquivados no repositório GitHub do projeto:

https://github.com/AndersonTavares0/llm-research-bench